



FACULTAD
DE CIENCIAS
ECONÓMICAS
Y DE ADMINISTRACIÓN

UNIVERSIDAD DE LA REPÚBLICA

FACULTAD DE CIENCIAS ECONÓMICAS Y DE
ADMINISTRACIÓN

TRABAJO FINAL DE GRADO

metasurvey

Paquete de R para el procesamiento de encuestas por muestreo con
generación de recetas mediante metaprogramación y estimación de
varianzas.

Estudiante:
Mauro Loprete

Tutora:
Dra. Natalia da Silva

**Trabajo final de grado presentado como requisito para la obtención
del título Licenciado en Estadística**

Resumen

metasurvey

por Mauro Loprete

El trabajo presenta *metasurvey*, un paquete de R diseñado para mejorar el procesamiento de encuestas por muestreo y la estimación de parámetros poblacionales. Utiliza meta-programación y técnicas de remuestreo para ofrecer resultados precisos, evaluar la incertidumbre y fomentar la reproducibilidad. A diferencia de otras bibliotecas, *metasurvey* combina flexibilidad mediante meta-programación con las capacidades de procesamiento de encuestas del paquete *survey*. Los objetivos incluyen proporcionar una herramienta útil, incorporar técnicas de remuestreo para usuarios no expertos, permitir la generación de ‘recetas’ personalizadas, y fomentar la contribución de la comunidad. Se destaca como alternativa a paquetes propietarios, enfocándose en la transparencia y reproducibilidad para mejorar la confiabilidad de las estimaciones poblacionales.

El tribunal docente integrado por los abajo firmantes aprueba el trabajo final de grado:

metasurvey Paquete de R para el procesamiento de encuestas por muestreo con generación de recetas mediante metaprogramación y estimación de varianzas.

Mauro Loprete

Tutor: Natalia da Silva

Licenciatura en Estadística

Calificación:

Fecha: 20/12/2024

Tribunal:

Ignacio Álvarez-Castro _____

Juan Pablo Ferreira _____

Natalia da Silva _____

Agradecimientos

Con profundo agradecimiento y emoción, quiero comenzar reconociendo a mi tutora, Natalia da Silva. Desde la clase de Nuevas Tecnologías para el Análisis de Datos, ella despertó en mí una pasión por el aprendizaje continuo y me motivó a explorar la importancia del uso y desarrollo de herramientas computacionales en la profesión de un estadístico. Además, Natalia siempre ha sido para mí una referente en lo que respecta al aprendizaje estadístico y el desarrollo de la comunidad de R, demostrando su compromiso con la innovación y el crecimiento de nuestra disciplina. Su apoyo incondicional, paciencia y disposición para guiarme en cada etapa de este proyecto fueron fundamentales, así como su confianza en mis capacidades. Más adelante, tuve la oportunidad de ser ayudante en la nueva versión llamada Ciencia de Datos con R, lo que me permitió continuar creciendo en este apasionante campo.

Quiero extender mi gratitud a todos los profesores de la Licenciatura en Estadística, quienes me brindaron las herramientas necesarias para llevar a cabo este trabajo. En particular, agradezco a Alejandra Marroig, cuyas ideas y consejos enriquecieron este proyecto al vincularlo con casos de uso de encuestas continuas de hogares. También a Ramón Álvarez, quien confió en mis capacidades desde el principio, permitiéndome aplicar herramientas computacionales que no solo alimentaron este proyecto, sino que también me dieron la oportunidad de compartir ese conocimiento en charlas internas en el IESTA.

A mis compañeros de la Licenciatura en Estadística, quiero agradecerles por los momentos compartidos a lo largo de esta carrera. Juntos atravesamos largas jornadas de estudio, debates y aprendizaje mutuo, mientras este proyecto comenzaba a tomar forma. En especial, quiero destacar a mis amigos Ana Vignolo y Maximiliano Saldaña, quienes siempre estuvieron allí para escucharme, brindarme su apoyo y ayudarme a mantener el enfoque en los momentos más desafiantes.

A mis compañeros de trabajo en Cognus, les agradezco profundamente por su comprensión y respaldo, permitiéndome equilibrar mis responsabilidades laborales con la dedicación necesaria para este proyecto. Su apoyo y ánimo fueron esenciales para alcanzar este objetivo.

No puedo dejar de mencionar a mis amigos, quienes contribuyeron desde sus propias perspectivas. A Fabricio Machado, por sus ideas, consejos y la posibilidad de probar ejemplos reales basados en encuestas continuas de hogares; a Matías Sesser, quien, aunque nunca entendió del todo qué trataba este proyecto, siempre me ofreció su apoyo incondicional y valiosos consejos sobre herramientas computacionales; y a Giannina, quien siempre estuvo dispuesta a escucharme en los momentos más difíciles, cuando la desmotivación me afectaba, dándome ánimo para seguir adelante. Su paciencia y comprensión significaron mucho para mí.

También quiero expresar mi más profundo agradecimiento a mis alumnos, quienes han sido una constante fuente de inspiración. Sus preguntas, curiosidad y entusiasmo me recordaron la importancia de seguir aprendiendo y compartiendo conocimientos. Cada clase fue una oportunidad de crecimiento mutuo, y su energía me impulsó a dar lo mejor de mí. Este trabajo también es para ellos, porque fueron y seguirán siendo una parte fundamental de mi camino.

Finalmente, quiero agradecer profundamente a mi familia, quienes siempre me brindaron su apoyo constante. A mi padre, Oscar, y a su esposa, Gabriela, quienes siempre me dieron confianza, aliento y amor incondicional. También a mis hermanos

y sobrinos, quienes llenaron mi camino de cariño y energía, aunque debo admitir que, como el resto de la familia, nunca terminaron de entender del todo qué hace exactamente un estadístico. Sin embargo, su apoyo y celebraciones en cada pequeño avance hicieron toda la diferencia. Y de manera muy especial, a mi sobrina Florencia, quien siempre estuvo dispuesta a escucharme en mis momentos de duda y frustración, dándome ánimo y fuerza para seguir adelante. Este logro también es de todos ellos.

A todos, gracias por ser parte de este viaje tan significativo en mi vida.

Índice

Resumen	iii
Agradecimientos	v
	1
1 Introducción	3
1.1 Motivación	3
1.2 Contexto	3
1.3 Antecedentes e implementaciones similares	5
1.4 Propuesta	5
1.5 Definición del Alcance	6
1.6 Desarrollo del paquete <code>metasurvey</code>	6
1.7 Esquema del documento	7
2 Marco conceptual	9
2.1 Inferencia en muestreo de poblaciones finitas	9
2.1.1 Diseño muestral	9
2.1.2 Probabilidades de inclusión y estimador de Horvitz-Thompson	10
2.2 2.1 Diseños muestrales: conceptos clave	11
2.2.1 Ponderación basada en el diseño y estimadores más comunes	11
2.3 2.2 Ponderadores y estimadores comunes	12
2.3.1 Medidas de incertidumbre y errores estándar	12
2.4 Desarrollo de paquetes en R	14
2.4.1 ¿Por qué desarrollar un paquete en R?	14
2.4.2 Elementos básicos de un paquete en R	15
2.5 Paradigmas de programación en R	15
2.5.1 Programación funcional	16
2.5.2 Programación orientada a objetos	16
2.5.3 Meta-programación	17
3 Marco teórico	19
3.1 Orden Lógico de la Reproducibilidad en el Análisis de Encuestas	19
3.1.1 Conceptos clave	21
3.1.2 Workflow reproducible	21
3.2 Investigación reproducible en R	22
3.2.1 Herramientas para el procesamiento de encuestas	22
3.3 Comparación de Paquetes para el Análisis de Encuestas	23
Resumen de las implementaciones	23
3.4 Diseño de encuestas y estimación de varianza	23
3.5 Herramientas para el desarrollo de paquetes en R	25
Implementación de tests automatizados	25

Documentación	26
Pruebas en diferentes sistemas operativos y versiones de R junto a GitHub Actions	27
4 Desarrollo y metodología	31
4.1 Estimación de los errores estándar	31
4.1.1 Métodos de remuestreo	32
4.2 Desarrollo e Implementación	34
4.2.1 Gestión de Dependencias	34
4.2.2 Arquitectura y Diseño de Clases	34
4.2.3 Implementación de Meta-programación	35
4.2.4 Ejemplos de la implementación	35
4.2.5 Meta-programación	39
4.2.6 Sistema de Comunicación y Optimización	40
4.3 Síntesis del capítulo	41
5 Casos de uso	43
5.1 Encuesta Continua de Hogares con Paneles Rotativos	43
5.1.1 Contexto y Cambios Metodológicos	43
5.1.2 Carga y Procesamiento de Datos	43
5.1.3 Construcción de Variables e Indicadores	44
5.1.4 Estimación de Tasas de Mercado de Trabajo	44
5.1.5 Visualización de las recetas	47
5.1.6 Compartiendo Recetas entre Usuarios	47
5.2 Resumen	48
6 Pasos a futuro	53
6.1 Optimización del rendimiento y escalabilidad	53
6.2 Expansión de funcionalidades estadísticas	53
6.3 Mejoras en la experiencia del usuario	53
Documentación y tutoriales	53
6.4 Integración y extensibilidad	54
Incorporación de scripts IECON compatibilizado	54
Sistema de validación de recetas	54
API y servicios web	54
6.5 Invitar a colaborar	54
6.6 Control de calidad y certificación	54
6.7 Visión a largo plazo	55
6.8 Conclusiones finales y visión de futuro	55
Bibliografía	57
Appendices	61
A Apendice	61

Lista de Tablas

3.1	Comparación de paquetes para análisis de encuestas	24
5.1	Tasas de mercado de trabajo a nivel trimestral a partir de las estimaciones mensuales de la ECH 2023 con sus respectivos errores estándar y coeficientes de variación.	45

Lista de códigos

1.1	Instalación de <code>metasurvey</code>	8
3.1	Ejemplo de un test automatizado para verificar el correcto funcionamiento de la función <code>extract_time_pattern</code>	26
3.2	Extracto de la documentación de la función <code>load_survey</code> con las etiquetas necesarias para la generación de la documentación.	27
3.3	Archivo de configuración de GitHub Actions para la ejecución de tests en diferentes sistemas operativos y versiones de R.	29
4.1	Lectura de la encuesta ECH 2022, fijación del ponderador y obtención de recetas.	36
4.2	Definición de la clase <code>Step</code> con sus atributos y método <code>initialize</code> para inicializar la clase. Las clases de <code>R6</code> son encapsuladas y permiten que los métodos y atributos sean privados o públicos.	38
4.3	Forma de desactivar la evaluación perezosa de los pasos y recetas. Esto hace que los pasos y recetas se apliquen de forma inmediata.	38
4.4	Desactivar el uso de referencias y utilizar copias de los objetos.	39
4.5	Ejemplo de función para encontrar dependencias de variables en una expresión de un <code>step</code> . Puede encontrar mas ejemplos en el código fuente en la implementación de los <code>Steps</code>	39
4.6	En este ejemplo se crea un nuevo ambiente <code>env</code> y se asignan valores a las variables <code>x</code>	40
4.7	40
4.8	En este ejemplo se muestra cómo se pueden reemplazar variables en una expresión utilizando <code>substitute</code> y cómo se puede evaluar parcialmente una expresión utilizando <code>bquote</code>	41
5.1	Carga de la encuesta continua de hogares en 2023, se carga la implantación y el seguimiento de la encuesta, se especifica el tipo de encuesta, el peso de la implantación y el peso del seguimiento, en este caso se utilizan pesos replicados bootstrap para el seguimiento de la encuesta.	49
5.2	Se puede ver las variables que dependen de la receta de ingreso compatibilizado para la ECH 2022.	49
5.3	Creación de variables para el cálculo de tasas de mercado de trabajo en los microdatos de seguimiento de la ECH 2023.	50
5.4	Estimación de tasas de mercado de trabajo a nivel trimestral a partir de las estimaciones mensuales.	51
5.5	Estimación de tasas de mercado de trabajo a nivel anual a partir de las estimaciones mensuales.	51
5.6	Carga de la encuesta y se obtienen las recetas disponibles referidas al tópico de mercado de trabajo.	52
5.7	Compartir receta de clasificación de la población por condición de actividad en la ECH 2019.	52

Capítulo 1

Introducción

Note

Este capítulo está en proceso de validación. Cualquier comentario es bienvenido

En este trabajo se presenta el paquete **metasurvey**, una herramienta para el procesamiento y obtención de indicadores a partir de encuestas por muestreo. El paquete proporciona al usuario control total y transparencia en el proceso de transformación de microdatos a indicadores, permitiendo validar y entender su construcción. Además, facilita la creación de variables sintéticas, recodificación de variables con criterios complejos y el tratamiento de variables continuas como el ingreso salarial mediante una metodología rigurosa y fácil de implementar. Es crucial que este proceso sea transparente y entendible para el usuario.

1.1 Motivación

Las encuestas por muestreo son una herramienta fundamental para la obtención de información sobre una población de interés, ya que permiten obtener datos a partir de una muestra representativa. Sin embargo, el procesamiento de encuestas puede ser tedioso, propenso a errores y difícil de transparentar y reproducir, especialmente al generar indicadores como tasas de mercado laboral, ingreso salarial e índices de pobreza (Vilhuber 2020).

Dado que las herramientas actuales no permiten flexibilidad al usuario, **metasurvey** se presenta como una alternativa que incorpora flexibilidad y transparencia en el proceso de transformación de microdatos a indicadores.

1.2 Contexto

En la teoría de la inferencia de poblaciones finitas, es crucial considerar la incertidumbre y los errores asociados a las estimaciones producidas. Generalmente, esto no es tomado en cuenta por usuarios no expertos en metodología de muestreo, lo que puede llevar a conclusiones erróneas. En algunos casos, el estimador asociado a la estimación puede tener una alta variabilidad o haber sido calculado sin considerar el diseño muestral correcto.

Es importante distinguir entre los enfoques de inferencia estadística **model-based inference** y **design-based inference** (Lumley 2011). En el primer enfoque, se asume que la población de interés puede modelarse mediante un modelo probabilístico, y se obtienen estimaciones de los parámetros del modelo mediante técnicas de inferencia

estadística. En el segundo enfoque, se asume que la población de interés es finita y se obtienen estimaciones de los parámetros de la población mediante técnicas de muestreo.

En este trabajo se mencionará intensivamente el concepto de peso o ponderador y su importancia en la estimación de varianzas y errores asociados a las estimaciones. En estadística, existen diferentes conceptos referidos a ponderadores o pesos, entre ellos (basado en (Lumley 2011)):

- **Pesos muestrales:** Refieren a la cantidad de veces que un individuo de la población de interés está representado en la muestra. Estos pesos provienen del diseño muestral, ya sea por el inverso de las probabilidades de selección, ajustes por no respuesta, entre otros.
- **Pesos de precisión:** Relacionados con la variabilidad que tiene una observación sobre la estimación de un parámetro.
- **Pesos de frecuencia:** Refieren a la cantidad de veces que aparece un individuo en una muestra y se resumen para incluir en un único registro.

Es importante hacer esta distinción ya que, tomando en cuenta los pesos en cualquiera de sus definiciones, en la mayoría de los casos **se pueden obtener estimaciones puntuales correctas**. Sin embargo, como se mencionó anteriormente, llegar a medidas de incertidumbre como errores estándar e intervalos de confianza puede ser incorrecto.

Además de la inferencia, es crucial considerar el proceso de transformación de los microdatos a indicadores para interpretar correctamente los indicadores y realizar comparaciones a lo largo del tiempo. Muchas veces, diferentes usuarios realizan el mismo esfuerzo de construcción de indicadores de manera independiente y sin compartir el código fuente o la metodología, ya que cada uno utiliza su propio estilo de programación o diferentes paquetes estadísticos, en su mayoría propietarios como SPSS, SAS o STATA. Aunque el usuario puede compartir la sintaxis para su construcción, esta está ligada al software y depende de que el usuario tenga el software instalado con una licencia activa.

En los últimos años, el uso de R (R Core Team 2023b) ha crecido exponencialmente en la comunidad científica, especialmente en estadística y ciencia de datos. R es un lenguaje de programación de código abierto ampliamente utilizado para el análisis de datos, estadística y aprendizaje automático. En R, se utiliza el concepto de *paquete* para referirse a una colección de funciones, métodos y clases que extienden las funcionalidades de R propuestas por la comunidad de usuarios. En este sentido, **metasurvey** busca ser una herramienta relevante para el trabajo con encuestas por muestreo en diversas disciplinas, solucionando las limitaciones mencionadas anteriormente.

Es importante definir el concepto de Estadística Computacional y su diferencia con Computación Estadística (Cook 2014), siendo este trabajo un aporte a la Estadística Computacional. La Estadística Computacional se refiere a la implementación de algoritmos y métodos estadísticos en un lenguaje de programación, mientras que la Computación Estadística se refiere a la utilización de herramientas computacionales para resolver problemas estadísticos. R permite realizar tanto Estadística Computacional como Computación Estadística, ya que cuenta con una amplia variedad de paquetes que permiten implementar algoritmos y métodos estadísticos y realizar análisis de datos de manera eficiente y reproducible.

1.3 Antecedentes e implementaciones similares

Actualmente existen diversos esfuerzos para facilitar el procesamiento de encuestas. Estos pueden clasificarse principalmente en dos tipos de paquetes:

- **Paquetes para inferencia estadística:** Implementan metodologías de inferencia en muestreo de poblaciones finitas, como **survey** (Lumley 2024), **gustave** (Chevalier 2023), **vardpoor** (Breidaks, Liberts, and Ivanova 2020), **svrep** (Schneider 2023) y **weights**.
- **Paquetes para encuestas específicas:** Permiten acceder y manipular datos de encuestas particulares:
 - **ech:** Procesa la **Encuesta Continua de Hogares (ECH)** del Instituto Nacional de Estadística (INE) de Uruguay (Detomasi 2020)
 - **eph:** Procesa la **Encuesta Permanente de Hogares (EPH)** del Instituto Nacional de Estadística y Censos (INDEC) de Argentina (Kozlowski et al. 2020)
 - **tidycensus:** Obtiene datos del **Censo de Estados Unidos** (Walker and Herman 2024)
 - **casen:** Procesa la **Encuesta de Caracterización Socioeconómica Nacional (CASEN)** del Ministerio de Desarrollo Social y Economía de Chile (Vargas 2024)

Sin embargo, estos últimos tienen limitaciones en cuanto a la flexibilidad y transparencia del proceso de transformación de los microdatos a indicadores de interés, como puede ser el índice de pobreza, tasas del mercado laboral, ingreso salarial, etc. En general, sus implementaciones son muy sensibles a la estructura y las variables que componen la encuesta, un cambio en la estructura de la encuesta suele implicar una actualización del paquete utilizado para obtener los indicadores en la nueva edición de la encuesta, lo que resulta poco flexible ante cambios en la estructura, que pueden ser frecuentes en la práctica. Además en las implementaciones actuales, el usuario cuenta con una función de alto nivel que actúa como una caja negra, donde no se permite modificar el código para adaptarlo a sus necesidades o entender cada paso que se realiza para obtener el indicador sin tener que leer el código fuente o la documentación adjunta.

1.4 Propuesta

Para científicos sociales, es importante tener en cuenta que el proceso de transformación de los microdatos a indicadores requiere de un conocimiento profundo de la encuesta y en su mayoría no es de conocimiento general. Es de interés obtener información histórica de indicadores y en general es un proceso tedioso y propenso a errores, especialmente si proviene de encuestas donde su estructura y/o forma de preguntar o su codificación puede cambiar con el tiempo. Esto resulta en un proceso extenso y difícil de entender hasta llegar a la construcción de esta serie de indicadores. Muchas veces, diferentes usuarios hacen el mismo proceso de construcción de indicadores de manera independiente y sin compartir el código fuente o la metodología de construcción de indicadores, ya que cada uno utiliza su propio estilo de programación o hasta diferentes paquetes estadísticos, en su mayoría propietarios como SPSS, SAS o STATA, donde si bien el usuario puede compartir la sintaxis para su construcción, esta está ligada al software y depende de que el usuario tenga el software instalado con una licencia activa y pueda correr el código.

En este sentido, es importante que el usuario pueda tener un control total sobre el proceso de transformación de los microdatos a indicadores, ya que esto permite que el usuario pueda validar y entender el proceso de construcción de indicadores, además de brindar una herramienta común libre de estilos de programación y definiendo con simples pasos el proceso de construcción de variables sintéticas, como recodificar variables creando grupos en base a criterios complejos, tratamiento de variables continuas como el ingreso salarial en base a una metodología rigurosa y fácil de referenciar en la implementación. Es crucial que este proceso sea transparente y entendible para el usuario. En capítulos posteriores se abordarán ejemplos con los paquetes mencionados anteriormente y se presentará el paquete `metasurvey` y su implementación de *recetas* para la construcción de indicadores mediante la meta-programación.

Al trabajar con encuestas por muestreo, es importante tener en cuenta la forma en la que se obtuvieron los datos y su proceso generador para poder realizar inferencias sobre la población de interés. En general, obtener estimaciones puntuales de estadísticos de totales, promedios o proporciones es relativamente sencillo, pero puede ser que se reporte una estimación donde no exista un tamaño de muestra suficiente para obtener una estimación confiable y/o que la variabilidad de la estimación sea alta y no sea recomendable su uso. En este sentido, es importante que el usuario no experto tenga de forma nativa una forma de obtener estimaciones puntuales y sus errores asociados de manera sencilla. Es común utilizar estimaciones puntuales sin tener una medida de incertidumbre o aún peor incluir una estimación del error estándar sin tener en cuenta el diseño muestral correcto, lo que puede llevar a conclusiones erróneas sobre la variabilidad de la estimación. `metasurvey` permite que el usuario pueda obtener estimaciones puntuales y sus errores asociados de forma nativa y con estos resultados hacer recomendaciones sobre la utilidad y confianza de la estimación mediante coeficientes de variación, intervalos de confianza, tamaño de muestra efectivo, entre otros sin tener que ser un experto en metodología de estimación de varianzas y remuestreo. En capítulos posteriores se abordarán ejemplos con los paquetes mencionados anteriormente y se presentará el paquete `metasurvey` y su implementación de estimaciones puntuales y sus errores asociados.

1.5 Definición del Alcance

`metasurvey` está diseñado para científicos sociales, estadísticos y economistas que trabajan con encuestas por muestreo. Permite a estos usuarios manejar y transformar microdatos en indicadores de manera transparente, flexible y reproducible.

1.6 Desarrollo del paquete `metasurvey`

El desarrollo de un paquete en R es un proceso que requiere contar con una idea bien formada y los medios para llevarla a cabo, es por esto que es importante contar con una metodología de trabajo ordenada, heredada del desarrollo de software convencional, ya que para la publicación y difusión del paquete se tienen que cumplir con ciertos estándares de calidad y documentación para que otros usuarios puedan utilizarlo. En este sentido, es importante tener en cuenta que el desarrollo de un paquete en R puede llevar tiempo y esfuerzo, a consecuencia de esto, en el documento se presentarán diferentes conceptos sobre metodología para el desarrollo de paquetes en R y se abordarán ejemplos con la implementación de `metasurvey`.

En este sentido, **metasurvey** pretende ser una herramienta relevante para el trabajo con encuestas por muestreo en general ya sea en las ciencias sociales o el uso genérico para otras disciplinas, buscando solucionar las limitaciones anteriormente mencionadas. Todo el proceso de transformación de los microdatos a indicadores se realiza a través de una serie de funciones que permiten al usuario tener un control total y transparente sobre el proceso de transformación de los microdatos a indicadores. Además, **metasurvey** permite que el usuario pueda realizar el proceso de transformación de los microdatos a indicadores de manera reproducible y transparente. El usuario puede compartir el código de una forma entendible, casi como un “recetario de cocina”. El procedimiento aplicado a los datos utilizados para obtener los indicadores se realiza mediante lo que denominamos *steps* y *recipes*, conformando así una especie de camino transparente para la construcción de indicadores. Esto permite compartir en forma visual un DAG (Directed Acyclic Graph) que permite visualizar el proceso de construcción de indicadores sin tener que abrir un script de R. En complemento al proceso de creación de variables, **metasurvey** permite que el usuario pueda obtener estimaciones puntuales y sus errores asociados de manera sencilla y brindar recomendaciones sobre la utilidad de la estimación en el caso de que se cuente con una variabilidad alta en la estimación, en base a recomendaciones a su coeficiente de variación o métricas similares.

El enfoque que permite la flexibilidad a la hora de construir los indicadores es la meta-programación. La meta-programación es un paradigma de programación que permite que un programa pueda modificar su estructura interna en tiempo de ejecución. En R, la meta-programación se realiza a través de las funciones `eval`, `parse`, `substitute`, `do.call` y `quote`, que permiten evaluar y parsear código de manera dinámica. En este sentido, **metasurvey** utiliza la meta-programación para permitir que el usuario pueda modificar el código que se utiliza para transformar los microdatos a indicadores, teniendo funciones de alto nivel similares a las que se utilizan en el paquete *recipes* de la librería *tidymodels* (Kuhn, Wickham, and Hvitfeldt 2024).

1.7 Esquema del documento

El documento se estructura de la siguiente manera: en el siguiente capítulo se presentará un marco conceptual básico sobre el muestreo de poblaciones finitas, diferentes paradigmas de programación como puede ser la programación orientada a objetos, programación funcional y la meta-programación y como se utilizan en el desarrollo del paquete. Luego, se ahondará en antecedentes previos tanto en la parte de metodología de estimación de varianzas y paquetes e ideas similares donde se basa el desarrollo del paquete. Finalmente, se presentarán ejemplos de cómo utilizar el paquete **metasurvey** para construir indicadores de mercado laboral a partir de los microdatos de la **ECH** y para mostrar su flexibilidad, se incluirá un ejemplo con la **EPH**.

Este documento puede leerse en su formato de [pagina web](#) o en su formato de [documento PDF](#). Tanto el código fuente del paquete se encuentran disponibles de forma pública en el repositorio de [Github](#) y el código fuente de este documento se encuentra disponible en el [repositorio](#). Para la realización de este documento se utilizó **quarto** (Publishing 2024) para la generación de documentos dinámicos que permiten escribir texto junto con código R.

Para finalizar, es importante mencionar que el paquete **metasurvey** es un proyecto en desarrollo y se encuentra en una etapa temprana de desarrollo, por lo que se espera que en el futuro se realicen mejoras y se agreguen nuevas funcionalidades, por lo

que se invita a la comunidad a colaborar en el desarrollo del paquete a través de la creación de [issues](#) en el repositorio de GitHub o mediante *pull requests* con mejoras o nuevas funcionalidades.

Para poder continuar con el documento, se recomienda instalar `metasurvey` en su versión de desarrollo, para ello se puede ejecutar el siguiente código [1.1](#)

Código 1.1 Instalación de `metasurvey`

```
branch <- "develop"

is_available <- "metasurvey" %in% rownames(
  available.packages(
    repos = "https://cloud.r-project.org/"
  )
)

if (is_available) {
  install.packages("metasurvey")
} else {
  remotes::install_github(
    "metasurveyr/metasurvey",
    ref = branch,
    force = TRUE
  )
  message("Se instaló la versión de desarrollo de metasurvey")
}
```

Capítulo 2

Marco conceptual

Note

Este capítulo está en proceso de validación. Cualquier comentario es bienvenido

El objetivo principal de este capítulo es presentar los conceptos básicos que se utilizarán a lo largo de este trabajo, en específico en el capítulo 3. Se introducirán ejemplos prácticos para facilitar la comprensión de inferencia en muestreo de poblaciones finitas.

2.1 Inferencia en muestreo de poblaciones finitas

Como fue mencionado anteriormente las encuestas por muestreo son la principal fuente de información para la construcción de indicadores socio-demográficos y económicos, en este sentido, es importante tener en cuenta un marco teórico para realizar estas inferencias. Es sumamente sencillo obtener estimaciones puntuales de un determinado estadístico aunque es importante considerar la variabilidad de los estimadores, tanto para poder realizar un proceso de inferencia completo así como también para poder cuantificar la confiabilidad de la estimación.

A continuación, se definen los conceptos básicos de inferencia en muestreo de poblaciones finitas como son el diseño muestral, probabilidades de inclusión basadas en el diseño, estimadores de Horvitz-Thompson **HT**, ponderación, medidas de incertidumbre y errores estándar basados en (Särndal, Swensson, and Wretman 2003).

2.1.1 Diseño muestral

El concepto de diseño muestral refiere al mecanismo mediante el cual se selecciona una muestra e inducen propiedades estadísticas claves como puede ser la distribución en el muestreo, valores esperados y varianzas de estimadores poblacionales. En diseños sencillos es posible calcular la función de diseño o encontrar una expresión analítica con facilidad mientras que en diseños mas complejos como pueden ser los multietapicos es necesario abordar el problema de otra forma y asumir ciertas hipótesis para poder construir probabilidades de inclusión tanto de primer orden como segundo orden el cual sera abordado en la sección 2.1.2

La definición matemática se basa en que dado un universo U de N elementos (puede ser conocido o no) $\{u_1, u_2, \dots, u_N\}$ y se considera un conjunto de tamaño n de elementos de U que se denota como $s = \{u_1, u_2, \dots, u_n\}$ al cual comúnmente denominamos **muestra**, el diseño muestral puede definirse de la siguiente forma:

$$Pr(S = s) = p(s)$$

Realizando un poco de inspección en la definición anterior se puede observar que el diseño muestral es una función de probabilidad que asigna una probabilidad a cada subconjunto de U de tamaño n . En este sentido, es posible definir diferentes tipos de diseño, entre ellos los mas comunes:

- **Diseño Aleatorio Simple (SI)**

El diseño aleatorio simple es el diseño más sencillo y se define de la siguiente forma:

$$p(s) = \frac{1}{\binom{N}{n}}$$

Ejemplo: Si se tiene una población de 1000 individuos y se desea seleccionar una muestra de 100 de manera aleatoria, cada combinación de 100 individuos tiene la misma probabilidad de ser seleccionada.

- **Diseño Bernoulli (BE)**

El **(BE)** es un diseño sencillo que se utiliza cuando se desea seleccionar una muestra de un universo de tamaño N además de considerar una probabilidad de inclusión π para cada elemento de U . Se define el diseño Bernoulli de la siguiente forma:

$$p(s) = \underbrace{\pi \times \pi \times \cdots \times \pi}_{n_s} \times \underbrace{(1 - \pi) \times (1 - \pi) \times \cdots \times (1 - \pi)}_{N - n_s} = \pi^{n_s} (1 - \pi)^{N - n_s}$$

Una diferencia fundamental entre el diseño **(BE)** y el diseño **SI** es que en el **BE** el tamaño de muestra es aleatorio y su distribución es binomial, mientras que en el diseño **SI** el tamaño de muestra es fijo.

- **Diseño Estratificado (ST)**

El diseño estratificado es un diseño que se utiliza cuando se desea seleccionar una muestra de tamaño n de un universo de tamaño N donde además se quiere dividir el universo en H estratos U_1, U_2, \dots, U_H . Dentro de cada estrato se selecciona una muestra de tamaño n_h y se define el diseño estratificado de la siguiente forma:

$$p(s) = \prod_{l=1}^H p(s_H)$$

En cada estrato se puede utilizar un diseño diferente pero en general se utiliza el diseño **SI**, mas conocido **STSI** (Stratified Simple Random Sampling). En este caso cada $p_h(s_h)$ es el diseño aleatorio simple en el estrato h .

2.1.2 Probabilidades de inclusión y estimador de Horvitz-Thompson

Una vez definido el concepto de diseño muestral es posible definir la probabilidad de que un elemento de la población sea seleccionado en la muestra, esta probabilidad se conoce como probabilidad de inclusión y se define de la siguiente forma:

- **Probabilidad de inclusión de primer orden**

$$\pi_k = Pr(u_k \in s) = Pr(I_k = 1)$$

Donde I_k es una variable aleatoria que toma el valor de 1 si el elemento u_k es seleccionado en la muestra y 0 en caso contrario. Definir estas variables indicadoras son de utilizada para entender el comportamiento de los estimadores bajo el diseño muestral y nos permite definir los estimadores en U y no en S . Es claro que $I_k \sim Bernoulli(\pi_k)$ y $E(I_k) = Pr(I_k) = \pi_k$.

Esta probabilidad es importante ya que es la base para la construcción de estimadores insesgados y eficientes, en este sentido, es posible definir el estimador de Horvitz-Thompson (**HT**) para estimar un total $t = \sum_U t_k$ de la siguiente forma:

$$\hat{t}_y = \sum_{k=1}^N \frac{y_k}{\pi_k} \times I_k$$

Este estimador es propuesto por Horvitz y Thompson en 1952 y es un estimador insesgado en el diseño, en el sentido de que $E(\hat{t}_y) = t$ y es eficiente en el sentido de que $Var(\hat{t}_y)$ es el menor posible entre los estimadores insesgados. Este estimador es muy utilizado en la práctica y es la base para la construcción de otros estadísticos, como medias, proporciones, varianzas, entre otros. Para mas detalles sobre las propiedades de Horvitz-Thompson (**HT**) se puede consultar en (Särndal, Swensson, and Wretman 2003) y (Horvitz and Thompson 1952).

2.2 2.1 Diseños muestrales: conceptos clave

2.2.1 Ponderación basada en el diseño y estimadores más comunes

En general es utilizado el concepto de ponderador para realizar estimaciones de totales, medias, proporciones, varianzas, entre otros. En este sentido, es posible definir el ponderador inducido por el diseño muestral de la siguiente forma:

$$w_k = \frac{1}{\pi_k}$$

Este ponderador puede interpretarse como el número individuos que representa el individuo k en la población. Este valor es el que comúnmente se publica junto a los microdatos y el estándar en los diferentes softwares para procesar encuestas. Junto al estimador de un total es posible definir el estimador de un promedio, proporción o razón en el contexto de la $\$$ -expansión.

Estimador de un promedio

$$\hat{\bar{y}} = \frac{\sum_{k=1}^N w_k I_k y_k}{\sum_{k=1}^N w_k I_k}$$

Este estimador puede ser utilizados en encuestas de hogares, donde se desea estimar el ingreso promedio de los hogares de una región de forma anual, o mensual.

Estimador de una proporción

$$\hat{p} = \frac{\sum_{k=1}^N I_k w_k y_k}{\sum_{k=1}^N w_k I_k} = \frac{\sum_{k=1}^N I_k w_k y_k}{\hat{N}}$$

Puede ser de interés estimar la proporción de hogares que tienen acceso a internet en una región, en este caso se puede utilizar el estimador de proporción.

Estimador de una razón

Se quiere estimar la razón $R = \frac{\sum_{k=1}^N y_k}{\sum_{k=1}^N z_k}$. En este caso se puede definir el estimador de la razón de la siguiente forma:

$$\hat{R} = \frac{\sum_{k=1}^N w_k y_k}{\sum_{k=1}^N w_k z_k} = \frac{\sum_{k=1}^N w_k y_k}{\hat{N}}$$

El estimador de razón es utilizado para construir variables de mercado de trabajo como la tasa de desempleo, tasa de ocupación, entre otros.

Inferencia sobre el tamaño de la población

Una vez definidos los estimadores, podemos ver que los estimadores de medias y proporciones son un caso particular del estimador de razón. Un detalle no menor es que asumimos N fijo pero desconocido, por esto al realizar proporciones se ajusta el total sobre un estimador del tamaño de la población:

$$\hat{N} = \sum_{k=1}^N I_k w_k$$

Existen diseños denominados **auto-ponderados** donde por definición $\sum_{k=1}^N w_k = N$, en este caso particular el estimador de medidas y proporciones es un caso particular del estimador de total, ya que el estadístico puede definirse de la siguiente forma:

$$\hat{y}_s = \frac{\sum_{k=1}^N I_k w_k y_k}{\sum_{k=1}^N w_k I_k} = \frac{\sum_{k=1}^N I_k w_k y_k}{N} = \frac{1}{N} \times \sum_{k=1}^N I_k w_k y_k = a \times \hat{t}_y$$

2.3 2.2 Ponderadores y estimadores comunes

2.3.1 Medidas de incertidumbre y errores estándar

Se puede medir la variabilidad de los estimadores y calcular su varianza. Para detalles completos de los cálculos de varianza, consulte el Apéndice A.

2.3.1.1 Momentos muestrales y estimadores de varianza

Para un estadístico θ , su varianza bajo un diseño muestral $p(s)$ se define como:

$$V(\hat{\theta}) = E((\theta - E(\hat{\theta}))^2) = \sum_{s \in S} p(s) (\hat{\theta}_s - E(\hat{\theta}_s))^2$$

La forma de calcular la varianza depende del estimador $\hat{\theta}$. Por ejemplo, para el estimador de varianza de un total, se utiliza la siguiente fórmula:

$$V(\hat{t}_y) = \sum_U V(I_k \times y_k \times w_k) + \sum_U \sum_{k \neq l} Cov(I_k \times y_k \times w_k, I_l \times y_l \times w_l)$$

Después de simplificar, obtenemos:

$$V(\hat{t}_y) = \sum_U V(I_k) \times w_k \times y_k^2 + \sum_U \sum_{k \neq l} Cov(I_k, I_l) \times y_k \times w_k \times y_l \times w_l$$

Donde definimos las siguientes identidades para simplificar cálculos:

$$Cov(I_k, I_l) = \Delta_{kl} = \pi_{kl} - \pi_k \times \pi_l$$

$$\check{y}_k = y_k \times w_k$$

$$\check{\Delta}_{kl} = \Delta_{kl} \times \frac{1}{\pi_{kl}} = \Delta_{kl} \times w_{kl}$$

Una vez definida la varianza del estimador, necesitamos estimar su varianza. Para esto, utilizamos la técnica de π -expansión. Después de algunas manipulaciones algebraicas, obtenemos la varianza del estimador:

$$V(\hat{t}_y) = \sum_U \check{y}_k^2 + \sum_U \sum_{k \neq l} \Delta_{kl} \times \check{y}_k \times \check{y}_l = \sum_U \sum \Delta_{kl} \times \check{y}_k \times \check{y}_l$$

Podemos verificar que este estimador de varianza es insesgado con las definiciones de $E(I_k I_l)$ y tomando esperanzas. Es decir, se verifica que $E(\hat{V}(\hat{t}_y)) = V(\hat{t}_y)$. Al ser un estimador insesgado, su eficiencia depende del diseño muestral y de la varianza de los ponderadores, es decir, de la varianza de las probabilidades de inclusión. En algunos casos, es donde entra en juego dividir grupos heterogéneos en estratos o realizar muestreos en varias etapas.

Para el caso de un estimador de un promedio, la varianza se define de la siguiente forma:

$$V(\hat{y}) = \frac{1}{N^2} \times \sum_U \sum_{k \neq l} \Delta_{kl} \times \check{y}_k \times \check{y}_l$$

Esto es válido en el caso de contar con un tamaño de población conocido. En otro caso, el estimador de la media no es un estimador lineal y para calcular su varianza deben optarse por métodos de estimación de varianzas más complejos como el de linealización de Taylor.

Es importante considerar que en esta sección se presenta un caso ideal donde la muestra es obtenida de un listado **perfecto** de la población objetivo denominado **marco de muestreo**. En la práctica, el marco de muestreo es imperfecto y se debe considerar la no respuesta, la cobertura y la falta de actualización del marco de muestreo. En general, para la publicación de microdatos se publican ciertos ponderadores que

no son precisamente los ponderadores originales definidos en la sección anterior, sino que son sometidos a un proceso de **calibración** donde se intenta ajustar a ciertas variables de control y mejorar problemas causados por la no respuesta. Al realizar el proceso de calibración, los ponderadores calibrados son lo más cercano posible a los ponderadores originales, de forma que si los ponderadores originales son insesgados, los ponderadores calibrados serán próximos a ser insesgados.

En la práctica, para diseños complejos no se dispone de las probabilidades de selección de segundo orden, insumo principal para calcular los errores estándar. Por esto, se requiere optar por metodologías alternativas como el método del último conglomerado, método de replicación jackknife, método de bootstrap, entre otros. En este sentido, es importante tener en cuenta que la varianza de los estimadores es un componente fundamental para realizar inferencias y cuantificar la confiabilidad de los resultados.

En resumen, para realizar estimaciones puntuales ya sean totales, medias, proporciones o razones, simplemente debemos ponderar los datos con los estadísticos anteriormente mencionados. Pero para realizar un proceso de inferencia completo se requiere calcular sus errores estándar, construir intervalos de confianza y/o poder medir la estabilidad de nuestros resultados. En este sentido, es importante tener al alcance herramientas que permitan realizar este tipo de cálculos, ya que en diferentes softwares estadísticos junto a la estimación puntual se presentan los errores estándar asumiendo diseños sencillos, lo cual puede ser erróneo.

Una vez presentados los conceptos básicos de muestreo, es importante entender cómo esto estará disponible en el paquete `metasurvey`. Se presentarán los conceptos básicos de programación funcional y orientada a objetos en R, para luego enfocarnos en la meta-programación.

2.4 Desarrollo de paquetes en R

R es un lenguaje de código abierto con una gran comunidad de usuarios en diversas áreas de investigación. Esto ha permitido el desarrollo de una gran cantidad de paquetes que facilitan tareas de análisis de datos, visualización, bioinformática, aprendizaje automático y otras ramas afines a la estadística. Dentro de la comunidad, existen organizaciones que se encargan de mantener la calidad de los paquetes y asegurar que cumplan con ciertos estándares. Una de estas organizaciones es el **Comprehensive R Archive Network (CRAN)**, un repositorio de paquetes de R que contiene versiones estables de los mismos. También existen otros repositorios como Bioconductor, que se especializa en análisis de datos biológicos, y rOpenSci, que se enfoca en la ciencia abierta.

2.4.1 ¿Por qué desarrollar un paquete en R?

Desarrollar un paquete en R tiene varias ventajas:

- **Reutilización de código:** Es posible que alguien ya haya escrito una función que uno necesita. Por lo tanto, siempre es bueno buscar si existe algún paquete que ya tenga las funcionalidades requeridas.
- **Compartir código:** La comunidad de R es muy activa y siempre está dispuesta a compartir código, lo que fomenta el desarrollo continuo de paquetes.
- **Colaboración:** El trabajo colaborativo es esencial en el desarrollo de paquetes en R, permitiendo que diferentes personas aporten nuevas funcionalidades, correcciones de errores, entre otros.

2.4.2 Elementos básicos de un paquete en R

Para que un conjunto de funciones, datos y documentación sea considerado un paquete en R, debe cumplir con ciertos requisitos mínimos:

- **Directorio:** Un paquete en R debe estar contenido en un directorio que incluya al menos los siguientes archivos y directorios:
 - **R/**: Contiene los archivos con las funciones del paquete.
 - **man/**: Contiene los archivos con la documentación de las funciones. Generalmente se utiliza *Roxxygen2* (Wickham, Danenberg, et al. 2024) para generar la documentación.
 - **DESCRIPTION**: Describe el paquete, incluyendo nombre, versión, descripción, autor, entre otros.
 - **NAMESPACE**: Contiene información sobre las funciones que se exportan y las dependencias del paquete.
 - **LICENSE**: Contiene la licencia bajo la cual se distribuye el paquete.
 - **README.md**: Proporciona información general sobre el paquete.
- **Documentación:** Es esencial para que los usuarios puedan entender el funcionamiento de las funciones del paquete. Se realiza utilizando el sistema de documentación de R, basado en comentarios en el código fuente.
- **Pruebas:** Es importante que el paquete tenga pruebas que verifiquen que las funciones se comportan como se espera. Las pruebas se realizan utilizando el paquete *testthat* (Wickham 2011a).
- **Control de versiones:** Permite llevar un registro de los cambios realizados en el paquete. El sistema de control de versiones más utilizado en la comunidad de R es **git**.
- **Licencia:** Permite a los usuarios utilizar, modificar y distribuir el paquete. La licencia más utilizada en la comunidad de R es la licencia MIT.

El proceso de subir un paquete a CRAN puede ser tedioso, ya que se deben cumplir ciertos requisitos revisados por los mantenedores de CRAN. Sin embargo, es un proceso que vale la pena, ya que permite que el paquete sea utilizado por una gran cantidad de usuarios.

El proceso de chequeo fue automatizado con GitHub Actions, por lo que cada vez que se realiza un cambio en el repositorio, se ejecutan los chequeos de CRAN y se notifica si el paquete cumple con los requisitos para ser publicado. En caso de que no cumpla con los requisitos, se notifica el error y no puede ser incluido en la rama principal del repositorio hasta que se corrija.

Todo el proceso y código fuente del paquete se encuentra disponible en el [repositorio de GitHub del paquete](#). Si está interesado en colaborar con el desarrollo del paquete, puede consultar la [guía de contribución](#).

2.5 Paradigmas de programación en R

R es un lenguaje de programación que permite realizar programación funcional y orientada a objetos (Chambers 2014), lo que permite que los usuarios puedan utilizar diferentes paradigmas de programación para resolver problemas. A continuación, se

presentan los conceptos básicos de la programación funcional y orientada a objetos en R.

2.5.1 Programación funcional

La programación funcional es un paradigma de programación que se basa en el uso de funciones para resolver problemas. En R, las funciones son objetos de primera clase, lo que significa que se pueden utilizar como argumentos de otras funciones, se pueden asignar a variables, entre otros (Wickham 2019, 204–81). A continuación, se presentan los conceptos básicos de la programación funcional en R.

- **Funciones de orden superior:** En R, las funciones de orden superior son funciones que toman como argumento una o más funciones y/o retornan una función. Un ejemplo de una función de orden superior en R es la función `lapply` que toma como argumento una lista y una función y retorna una lista con los resultados de aplicar la función a cada elemento de la lista.
- **Funciones anónimas:** En R, las funciones anónimas son funciones que no tienen nombre y se crean utilizando la función `function`. Un ejemplo de una función anónima en R es la función `function(x) x^2` que toma como argumento `x` y retorna `x^2`.
- **Funciones puras:** En R, las funciones puras son funciones que no tienen efectos secundarios y retornan el mismo resultado para los mismos argumentos. Un ejemplo de una función pura en R es la función `sqrt` que toma como argumento un número y retorna la raíz cuadrada de ese número.

Este paradigma de programación es muy útil para realizar análisis de datos, ya que permite que los usuarios puedan utilizar funciones para realizar operaciones sobre los datos de manera sencilla y eficiente. Dentro de `metasurvey` no existe una presencia fuerte de programación funcional, sin embargo, se utilizan algunas funciones de orden superior para realizar operaciones sobre los datos.

2.5.2 Programación orientada a objetos

La programación orientada a objetos es un paradigma de programación que se basa en el uso de objetos para resolver problemas. En R, los objetos son instancias de clases que tienen atributos y métodos (Wickham 2019, 285–370; Mailund 2017). A continuación, se presentan los conceptos básicos de la programación orientada a objetos en R.

- **Clases y objetos:** En R, las clases son plantillas que definen la estructura y el comportamiento de los objetos y los objetos son instancias de clases. En R, las clases más utilizadas provienen del sistema de programación orientada a objetos llamado `S3`. Las clases se definen utilizando la función `setClass` y los objetos se crean utilizando la función `new`. También se pueden utilizar las clases del sistema `S4`, aunque este tiene una sintaxis más compleja y no es tan utilizado.
- **Atributos y métodos:** En R, los atributos son variables que almacenan información sobre el estado de un objeto y los métodos son funciones que permiten modificar el estado de un objeto. En R, los atributos se definen utilizando la función `setClass` y los métodos se definen utilizando la función `setMethod`.

Dentro de `metasurvey` se utiliza la programación orientada a objetos para definir las clases de los objetos que se utilizan para representar los datos de las encuestas

mediante la creación de una clase específica llamada `Survey` que permite, además de almacenar los datos de la encuesta, añadir atributos y métodos que permiten realizar operaciones sobre los datos de manera sencilla y eficiente.

De forma similar se modelan las clases `Step`, `Recipe` y `Survey`, entre otras, elementos cruciales en el ecosistema de `metasurvey` donde se definen los pasos de preprocesamiento, recetas de preprocesamiento y flujos de trabajo respectivamente. En este caso particular se utiliza el paquete *R6* (Chang 2022) que permite definir clases de manera intuitiva y eficiente, además de permitir la herencia de clases y la definición de métodos y atributos de manera sencilla.

2.5.3 Meta-programación

La meta-programación es un paradigma de programación que se basa en el uso de código para manipular código (Wickham 2019, 373–500; Thomas Mailund 2017). En R, la meta-programación se realiza utilizando el sistema de meta-programación de R que se basa en el uso de expresiones, llamadas y funciones. A continuación, se presentan los conceptos básicos de la meta-programación en R.

- **Expresiones:** En R, las expresiones son objetos que representan código y se crean utilizando la función `quote`. Un ejemplo de una expresión en R es la expresión `quote(x + y)` que representa el código `x + y`.
- **Llamadas:** En R, las llamadas son objetos que representan la aplicación de una función a sus argumentos y se crean utilizando la función `call`. Un ejemplo de una llamada en R es la llamada `call("sum", 1, 2, 3)` que representa la aplicación de la función `sum` a los argumentos 1, 2 y 3.
- **Funciones:** En R, las funciones son objetos que representan código y se crean utilizando la función `function`. Un ejemplo de una función en R es la función `function(x, y) x + y` que representa el código `x + y`.

En `metasurvey` se utiliza la meta-programación para generar código de manera dinámica y realizar operaciones sobre los datos de manera eficiente. En particular, se utiliza la función `eval` para evaluar expresiones y la función `substitute` para reemplazar variables en expresiones. Además, se utilizan las funciones `lapply`, `sapply`, `mapply` y `do.call` para aplicar funciones a listas y vectores de manera eficiente. En general, la meta-programación es una técnica muy útil para realizar operaciones sobre los datos de manera eficiente y sencilla.

En el capítulo 3 se presentarán los antecedentes de metodologías de estimación de varianzas, revisión de medidas de incertidumbre, paquetes similares y mejoras que son incorporadas en el paquete `metasurvey`. En el capítulo 4 se hablará sobre la implementación de las diferentes partes que conforman el paquete, una breve reseña del esquema de test, la API para almacenar las recetas junto a su interacción con el usuario. Posteriormente se mostrará un ejemplo de uso del paquete y se presentarán las conclusiones y trabajos futuros.

Capítulo 3

Marco teórico

Note

Este capítulo está en proceso de validación. Cualquier comentario es bienvenido

En este capítulo se presentan los antecedentes y conceptos aplicados en el desarrollo de `metasurvey`. Se abordan conceptos de investigación reproducible, la importancia de R como herramienta, la revisión de paquetes para el procesamiento de encuestas por muestreo y la relevancia del diseño muestral. También se analiza la importancia de la estimación de las varianzas en la generación de indicadores y los trabajos previos en los que se basa el paquete. Estos conceptos son fundamentales para comprender el desarrollo y la importancia de establecer un flujo de trabajo sistemático en la generación de indicadores sociales.

En la actualidad, la generación de indicadores sociales se ha convertido en una tarea fundamental tanto para la toma de decisiones como para la investigación. Sin embargo, este proceso puede resultar complejo, ya que requiere conocimiento específico sobre el formulario de la encuesta y formas de construir ciertos índices o variables auxiliares que no necesariamente son triviales y dependen de la experiencia del usuario.

Este proceso de generación de indicadores frecuentemente carece de transparencia o documentación adecuada, en parte por la ausencia de herramientas apropiadas y en parte por la falta de una cultura de reproducibilidad, ya que generalmente solo se hace referencia a los datos y no al proceso completo de generación de los indicadores.

3.1 Orden Lógico de la Reproducibilidad en el Análisis de Encuestas

El concepto de investigación reproducible ha cobrado relevancia en los últimos años, tanto en la academia como en la industria y esto se debe a la fricción que puede llegar a existir al momento de presentar resultados de investigación o generación indicadores relevantes para la toma de decisiones debido al proceso de generación de los mismos. Dentro de las diferentes disciplinas generar ambientes de trabajo reproducibles puede llegar a ser un desafío, ya que en la mayoría de los casos se utilizan diferentes herramientas, lenguajes de programación y bases de datos.

En la actualidad existen diferentes revistas científicas que promueven la investigación reproducible, herramientas, guías para buenas prácticas para trabajar con datos y código fuente como Sumatra (Davison and Huth 2012), implementaciones de programación literal (Knuth 1984) como RMarkdown (Allaire et al. 2024) o Jupyter

Notebook (Kluyver et al. 2024) y diferentes implementaciones para gestionar dependencias de software como Anaconda (Anaconda 2024), aunque algunas de ellas se han vuelto herramientas de pago o ya no existen en la actualidad, mas referencias y casos de uso pueden encontrarse en (Stodden, Leisch, and Peng 2014).

Antes de continuar es necesario definir conceptos fundamentales en el ámbito de la investigación reproducible, tales como la *Reproducibilidad* que refiere a la capacidad de poder repetir los resultados de un estudio, experimento o la obtención de un indicador. Si bien la reproducibilidad es considerada en un artículo de investigación científica al utilizar indicadores tanto en contextos académicos como en aplicaciones de monitoreo o divulgación de información, rara vez se documenta o se menciona de que manera se generó ese resultado haciendo referencia únicamente a los datos y rara vez al código fuente. Aún compartiendo el código fuente, esto aún no es suficiente para poder reproducir un estudio o un indicador por incompatibilidades de versiones de software, cambios en la estructura de los datos interpretaciones de los datos, estilos de programación, entre otros pudiendo llevar mucho tiempo y esfuerzo para poder replicar un resultado.

El proceso de tratamiento de datos y limpieza forma parte de lo que se conoce como *publicaciones grises* (Vilhuber 2020). Este concepto se refiere a la publicación de datos, código y reportes que no son publicaciones formales, pero son esenciales para generar conocimiento científico. En su mayoría al no tener una revisión por pares o una forma estandarizada esto se incluye de forma muy dispar o sin ningún tipo de documentación para poder ser reproducido y esto forma una gran parte de la investigación científica que no se encuentra aprovechada.

Existen diversas iniciativas destinadas a fomentar la reproducibilidad en la ciencia, lo que ha llevado a las revistas a establecer políticas de datos y código abierto. Sin embargo, persisten desafíos en la generación de indicadores sociales, ya que como se menciono anteriormente no basta con hacer referencia a los datos, como se señala en (Bechhofer et al. 2013); además de publicar el artículo junto a los datos, es necesario vincular los objetos de investigación (Research Objects **RO**), existen diferentes plataformas que permiten la publicación de estos objetos como **Zenodo** y **Figshare** o **OSF** que permiten la integración de datos, código e interacción con repositorios con control de versiones como GitHub o GitLab.

De conceptos generales sobre reproducibilidad es importante contar con un flujo de trabajo (*Workflow management System* (Prabhu and Fox 2020)) para la obtención de estimadores en el procesamiento de encuestas por muestreo ya que el indicador final es el resultado de una serie de pasos que se deben seguir de manera ordenada y documentada para poder ser auditados y replicados en diferentes contextos, inspirado en (Sandve et al. 2013) se pueden considerar algunas buenas prácticas para la generación de indicadores:

- **Para cada resultado, se debe tener un respaldo de como fue construido:** Al trabajar con lenguajes de programación como R, los script de código fuente son un respaldo de como obtener cierto resultado, sin embargo, esto puede estar ligado a tu estilo de programación y la versión de los paquetes que se utilizan.
- **Crear manuales en la manipulación de datos:** Es importante resumir cada paso por mas mínimo que sea en la transformación de variables, esto permite entender todo el proceso de generación de un indicador.

- **Guardar las versiones de los paquetes utilizados:** Al trabajar con R, es importante guardar las versiones de los paquetes que se utilizan, esto permite que en un futuro se pueda replicar el proceso de generación de indicadores, para esto puede utilizarse herramientas como **renv** (Ushey and Wickham 2023) un paquete que permite crear ambientes locales con versiones específicas de paquetes de R, **venv** (Python Software Foundation 2024) que son ambientes virtuales en python o Docker (Merkel 2014) para poder emular un ambiente de trabajo en diferentes sistemas operativos.
- **Guardar pasos intermedios, en un formato estándar:** Al trabajar con encuestas por muestreo y para crear indicadores sencillos se realizan dos grandes tipos de operaciones: crear grupos o categorías o realizar operaciones matemáticas, es importante guardar estos pasos en un formato estándar para poder ser reutilizados en diferentes contextos.
- **Compartir las ejecuciones y scripts:** Es importante que los scripts de código fuente estén disponibles para que puedan ser auditados y replicados en diferentes contextos.

3.1.1 Conceptos clave

metasurvey se basa en las buenas prácticas mencionadas anteriormente y permite crear herramientas de flujo de trabajo siguiendo los siguientes principios:

- **Reusable:** Se separa el proceso de transformación de variables en **Steps** que refiere a transformaciones de columnas, estos procedimientos pueden ser comunes tanto en diferentes encuestas como en diferentes indicadores. Estos **Steps** pueden ser reutilizados en diferentes **Recipes** para calcular indicadores de mercados de trabajo, pobreza, e incluso aplicarlos en varias encuestas simultáneamente mediante un **Workflow**.
- **Repetible:** Al tener un proceso definido en un **Workflow**, es posible repetir el proceso de generación de indicadores de la misma manera y automatizar la generación de reportes.
- **Referenciable y Acreditable:** Al contar con un **Workflow**, es posible hacer referencia al proceso de generación de indicadores indicando todos los pasos seguidos y el autor o equipo que lo realizó. Además, se puede acreditar a los autores de los **Steps** y **Recipes** que se utilizaron en el proceso.

3.1.2 Workflow reproducible

El concepto de *Workflow* no es nuevo y exclusivo en la comunidad científica, en la actualidad en la industria de la ciencia de datos se han desarrollado diferentes herramientas para la gestión de flujos de trabajo para el procesamiento de datos, con diferentes enfoques y objetivos. **metasurvey** se inspira en diferentes herramientas como **Apache AirFlow** (“Apache Airflow Documentation,” n.d.) que es una plataforma de orquestación de flujos de trabajo de código abierto, **Great Expectations** (Expectations 2024) que es una biblioteca de validación de datos para la generación de reportes de calidad de datos y **Make** que es una herramienta de automatización de flujos de trabajo que se basa en la definición de reglas y dependencias.

En el ámbito del aprendizaje automático existe un gran esfuerzo para poder desgarnar y documentar los modelos conocido como **Model Cards** (Mitchell et al. 2019)

donde se hace un detalle de los algoritmos utilizados, las métricas de evaluación, los datos utilizados y su procesamiento, siendo esto el análogo a los **Steps** y **Recipes** de **metasurvey**. Este concepto se ha extendido siendo un estándar en la industria y siendo adoptado por diferentes organizaciones como **Google** y **Hugging Face**.

Tomando en cuenta estos conceptos, **metasurvey** tiene disponible la posibilidad de generar, compartir y visualizar los flujos de trabajo de manera gráfica permitiendo la transparencia y auditabilidad de los procesos de generación de indicadores.

3.2 Investigación reproducible en R

Dentro de CRAN existe una guía sobre conjunto de paquetes y herramientas con objetivos comunes denominado **Task Views** que agrupa paquetes de R que se utilizan para un propósito específico. En el Task View de **Reproducible Research** se encuentran diferentes paquetes que permiten la generación de reportes dinámicos, la gestión de flujos de trabajo y la generación de documentos interactivos aunque también existen herramientas para la gestión de flujos de trabajo generales como **targets** (Landau 2021) y **drake** (Landau 2018), **metasurvey** fue inspirado en los conceptos y la forma de trabajo de estos paquetes.

Los conceptos de meta-programación y programación orientada a objetos fue inspirado en el paquete **mlr3pipelines** (Binder et al. 2021) que permite la creación de flujos de trabajo para el preprocesamiento de datos y la generación de modelos de aprendizaje automático, aquí se definen **PipeOps** que son operaciones que se pueden aplicar a los datos y se pueden combinar en un **Graph** que define el flujo de trabajo para ello se definen clases y métodos que permiten una fácil extensión por parte del usuario y la creación de flujos de trabajo complejos.

Dentro de la comunidad existen organizaciones como **rOpenSci** que promueven la ciencia abierta y la reproducibilidad en la investigación científica, proporcionando herramientas y guías para promover la ciencia abierta mediante R. Esta organización promueve la creación de paquetes donde además de la guías sobre el desarrollo de paquetes y la revisión de los mismos, se promueve la creación de paquetes que sean de utilidad para la comunidad científica definiendo estándares de calidad y documentación. Para formar parte de **rOpenSci**, se sigue una evaluación entre pares y una revisión de la calidad del paquete, además de la documentación y la calidad del código complementado con tests automatizados.

3.2.1 Herramientas para el procesamiento de encuestas

En el ámbito de las encuestas por muestreo, existen diferentes paquetes que permiten el procesamiento de encuestas por muestreo o la generación de estadísticas oficiales, esto se puede ver en el Task View de **Official Statistics & Survey Methodology** donde se encuentran diferentes tipos de paquetes desde la preparación de formularios, calibración, análisis de datos, acceso a datos oficiales, entre otros.

Para el procesamiento de encuestas por muestreo, existe una serie de paquetes que permiten implementar la metodología de encuestas por muestreo como puede ser el caso de **survey** (Lumley 2024) que permite el análisis de encuestas complejas, **srvyr** (Ellis and Schneider 2023) aunque estos son utilizados en el proceso final o de inferencia y no en el proceso de la construcción y limpieza de los datos como si lo hace **ech** (Detomasi 2020) que tiene diferentes funciones para la ECH y permite al usuario crear variables referidas a Vivienda, Educación, Mercado de Trabajo, Ingresos

y Pobreza algo similar con **eph** (Kozłowski et al. 2020) que permite la descarga de datos de la EPH y la creación de variables para analizar la pobreza y el mercado de trabajo.

Este ultimo grupo de paquetes o **caja de herramientas** tienen la limitación que no permiten la reutilización de los pasos de limpieza y transformación de los datos de forma sencilla y nativa, además de no poder visualizar el flujo de trabajo de manera gráfica, lo que dificulta la auditoría y la replicabilidad de los procesos de generación indicadores, **metasurvey** busca llenar este vacío permitiendo la reutilización de los pasos de limpieza y transformación de los datos, la visualización del flujo de trabajo y la generación de reportes de manera sencilla.

3.3 Comparación de Paquetes para el Análisis de Encuestas

Resumen de las implementaciones

En la Tabla 3.1 a continuación se presenta un resumen de las implementaciones de los paquetes mencionados anteriormente:

```
#> file:///tmp/RtmptxtUTr/file225c1e1b4044.html screenshot completed
```

Como se puede observar en la Tabla 3.1, **metasurvey** busca llenar el vacío de la reutilización de los pasos de limpieza y transformación de los datos de manera sencilla y visualizar el flujo de trabajo, aprovechando como dependencia **survey** y **svrep** para la estimación de varianzas y la generación de indicadores sociales, permitiendo la generación de reportes de manera sencilla y visualizar el flujo de trabajo de manera gráfica.

3.4 Diseño de encuestas y estimación de varianza

Como fue introducido en el capítulo anterior y en la sección de antecedentes es sencillo obtener estimaciones puntuales, sin embargo, es necesario presentar una medida de precisión de la estimación ya que en algunos casos puede ser que el tamaño de la muestra no sea suficiente para obtener estimaciones precisas. En el caso de las encuestas por muestreo, es necesario tener en cuenta el diseño de la encuesta, la estratificación, la ponderación y el efecto de conglomerados, ya que estos factores influyen en la precisión de la estimación. Para ello, es necesario contar con alguna metodología que permita estimar varianzas ya que para diseños complejos o estadísticos no lineales, la estimación de varianzas no es trivial.

En la actualidad, existen diferentes métodos para la estimación de varianzas, aunque en la mayoría de los casos se utilizan métodos de remuestreo como el Bootstrap o el Jackknife, sin embargo existen diferentes ideas o propuestas como se menciona en (Deville and Tille 1998) y (Deville and Tillé 2005) que demuestran con resultados numéricos estimadores del tipo **H-T** bajo un diseño balanceado puede aproximarse desde el enfoque de regresión o calibración. Además existen estimadores alternativos donde complementan métodos de remuestreo para aproximar probabilidades de inclusión de segundo orden (Emilio L. Escobar and Berger 2013) utilizando ciertas aproximaciones límites (Hajek 1964).

Cada metodología depende de cada diseño y variables a estimar, por esto es que existen diferentes metodologías y paquetes como **gustave** (Chevalier 2023) , **vardpoor**

TABLA 3.1: Comparación de paquetes para análisis de encuestas

Comparación de Paquetes para Análisis de Encuestas		
Información actualizada sobre versiones y últimos commits		
Paquete	Descripción	Último Commit
survey	Permite el análisis de encuestas complejas, aquí se pueden definir los estratos, los conglomerados y las ponderaciones, además tiene implementaciones de los estimadores más comunes como el estimador de Horvitz-Thompson, el estimador de regresión y el estimador de calibración. Sin embargo, dentro de este mismo paquete no existe una forma de integrar los pasos de limpieza y transformación de los datos de manera sencilla y visualizar el flujo de trabajo. Este paquete es utilizado como dependencia clave para ocupar los principales estimadores poblacionales y diseño muestral.	2024-03-20T15:30:02Z
svyr	Es una interfaz para el paquete survey que permite trabajar con dplyr y tidyverse, sin embargo, no permite de forma nativa la reutilización de los pasos de limpieza y transformación de los datos de manera sencilla y visualizar el flujo de trabajo aunque permite la integración con dplyr y tidyverse. Este paquete cuenta con muchas dependencias debido al uso de tidyverse y va en contra de la filosofía de metasurvey de tener la menor cantidad de dependencias posibles. Además metasurvey tiene su propia capa de abstracción para trabajar con survey.	2024-10-05T17:06:52Z
gustave	Cuenta con una función principal qvar que no utiliza el diseño muestral como argumento sino que se deben de ingresar las probabilidades de inclusión y no queda del todo claro los estadísticos que se pueden obtener. Además, no permite la reutilización de los pasos de limpieza y transformación de los datos de manera sencilla y visualizar el flujo de trabajo. Si bien tiene diferentes implementaciones de aproximación de varianzas como la de Deville y Tillé, no es la forma de estimación que utiliza metasurvey por defecto aunque puede ser una alternativa para futuras implementaciones.	2024-01-15T16:56:39Z
vardpoor	Este paquete utiliza la estimación de varianzas por el método de último conglomerado, otras métricas como el efecto diseño, linealización del estimador de razón, coeficiente de Gini y diferentes estadísticos enfocados en la desigualdad. Si bien es una implementación interesante, su sintaxis es particular y ajena a la del paquete survey, tiene muy pocas dependencias pero puede ser implementado como motor de estimación de varianzas en futuras implementaciones.	2022-02-17T14:50:27Z
convey	Este paquete sí utiliza el diseño muestral como argumento e implementa algunos estadísticos que se incluyen en vardpoor, sin embargo, no permite la reutilización de pasos de limpieza y transformación de los datos de manera sencilla y visualizar el flujo de trabajo. Sin embargo, al tener una implementación del diseño muestral, se sincroniza muy bien con metasurvey. Los estadísticos pueden ser utilizados de forma nativa en metasurvey.	2024-10-17T13:19:17Z
svrep	Extensión del paquete survey para trabajar con réplicas sobre los pesos muestrales, permite la estimación de varianzas por el método de Bootstrap, Jackknife y replicación de balanceo. La integración con el diseño del tipo bootstrap y jackknife. Este paquete es utilizado como dependencia clave para ocupar los principales estimadores poblacionales y diseño muestral y es utilizado en metasurvey para la estimación de varianzas.	2024-04-26T18:40:02Z
Datos extraídos desde GitHub a través de la API.		

(Breidaks, Liberts, and Ivanova 2020), `svrep` (Schneider 2023) y `samplingVarEst` (Emilio Lopez Escobar, Zamudio, and Rosas 2023), aunque existen similitudes entre implementaciones y métodos es difícil encontrar una implementación que permita la estimación de varianzas de manera sencilla y que permita la reutilización de los pasos de limpieza y transformación de los datos, esto puede ser complicado para usuarios que no tienen experiencia en el procesamiento de encuestas por muestreo y que buscan una herramienta que les permita realizar este tipo de análisis de manera sencilla y visual.

3.5 Herramientas para el desarrollo de paquetes en R

Cualquier usuario puede desarrollar un paquete en R, aunque existen diferentes guías y estándares para el desarrollo de paquetes en R, como se menciona en (“R Packages (2e),” n.d.) , además de la guía de rOpenSci (rOpenSci et al. 2024) que promueve la creación de paquetes que sean de utilidad para la comunidad científica definiendo estándares de calidad y documentación.

Para el desarrollo de `metasurvey` se utilizaron paquetes como `usethis` (Wickham, Bryan, et al. 2024) que permite la creación de paquetes en R, `roxygen2` (Wickham, Danenberg, et al. 2024) que permite la documentación de funciones y la creación de manuales, `testthat` (Wickham 2011b) que permite la creación de tests automatizados, `pkgdown` (Wickham, Hesselberth, et al. 2024) que permite la creación de sitios web para paquetes de R, `devtools` (Wickham et al. 2022) que permite la instalación y la carga de paquetes en R, `renv` (Ushey and Wickham 2023) que permite la creación de ambientes locales con versiones específicas de paquetes de R junto a herramientas como pre-commit (Sottile and Contributors 2024) que permite la ejecución de scripts antes de realizar un commit en un repositorio de git esto con el fin de mantener la calidad del código y la documentación antes de realizar un cambio en el repositorio. De forma conjunta se utilizó GitFlow (Driessen 2010) que es una metodología de trabajo con git que permite la colaboración y la integración continua de los cambios en un repositorio de git. Para la automatización de los tests en diferentes sistemas operativos se utilizó GitHub Actions (*GitHub Actions: Automate Your Workflow* 2024) que permite la ejecución de scripts en diferentes sistemas operativos y la generación de reportes de cobertura de código con Codecov (*Codecov: Code Coverage Insights* 2024).

Todo estas herramientas permiten que la creación de paquetes sea sencilla y permita a los usuarios enfocarse en la implementación con cierto grado de calidad y documentación, además de permitir la colaboración y la integración continua de los cambios en un repositorio de git.

Implementación de tests automatizados

El paquete incluye tests automatizados creados con `testthat`, lo que asegura la robustez del código fuente al ser utilizado en diversos contextos. Un ejemplo es el test de la función `extract_time_pattern`, que analiza el nombre de una encuesta y retorna su tipo, año y periodicidad. Esta función clave utiliza expresiones regulares para manejar distintos formatos de tiempo y es fundamental para tareas como definir la edición de encuestas o emparejar réplicas bootstrap. Su implementación completa puede encontrarse aquí: [extract_time_pattern](#).

Código 3.1 Ejemplo de un test automatizado para verificar el correcto funcionamiento de la función `extract_time_pattern`.

```
test_that(
  "Probar extraer time pattern anual",
  {
    testthat::expect_equal(
      metasurvey::extract_time_pattern("ECH_2023"),
      list(
        type = "ECH",
        year = 2023,
        periodicity = "Annual"
      )
    )
  }
)
```

Al tener una serie de test automatizados como el presentado en el código 3.1 se realice antes de realizar cambios en el código fuente pueda el desarrollador ejecutar los tests y verificar que no existan problemas ante un cambio o una refactorización del código fuente. Para el envío a CRAN se realizan estos test automático y una serie de pruebas de calidad y documentación para que el paquete sea aceptado en CRAN. Actualmente `metasurvey` no tiene errores, mensajes de advertencia o notas en CRAN, la cobertura del código es bastante baja ya que realizar test para todas las funciones es un trabajo arduo y que requiere tiempo, sin embargo en futuras versiones se espera tener una cobertura del código mayor al 80%. La cobertura puede ser verificada en el siguiente enlace: [codecov](#).

Documentación

Para la documentación se utilizó `roxygen2` que permite la documentación de funciones y la creación de manuales, además de `pkgdown` que permite la creación de sitios web para paquetes de R, esto permite que los usuarios puedan tener una guía de referencia para utilizar el paquete y que los desarrolladores puedan tener una guía de referencia para la implementación de nuevas funciones o la modificación de las existentes.

Como se puede observar en el código 3.2, la documentación de las funciones se realiza con comentarios en el código fuente, esto permite que `roxygen2` pueda generar la documentación de las funciones y los manuales de manera automática, simplemente hay que añadir comentarios con ciertas etiquetas que dependiendo si la función es exportada o no, es un requisito para la aceptación en CRAN que las funciones que se exporten estén documentadas y que la documentación sea clara y concisa. La documentación puede ser consultada en el siguiente enlace: [Documentación de metasurvey](#) o en la ayuda de R con `?load_survey`.

Código 3.2 Extracto de la documentación de la función `load_survey` con las etiquetas necesarias para la generación de la documentación.

```
#' @title Load survey
#' @param path Path to the survey file
#' @param svy_type Type of survey
#' @param svy_edition Edition of the survey
#' @param svy_weight Weight of the survey
#' @param svy_psu Primary sampling unit
#' @param ... Additional arguments
#' @param bake Logical
#' @return Survey object
#' @keywords preprocessing
#' @export
load_survey <- function(
  path = NULL,
  svy_type = NULL,
  svy_edition = NULL,
  svy_weight = NULL,
  svy_psu = NULL,
  ..., bake = FALSE) {
  # Ejemplo no mostrado debido a la extensión del
  # código puede ser consultado en
  # el repositorio de GitHub
}
```

Pruebas en diferentes sistemas operativos y versiones de R junto a GitHub Actions

En muchos casos, los paquetes de R pueden tener problemas de compatibilidad con diferentes versiones de R o con diferentes sistemas operativos, para evitar estos problemas se utilizó GitHub Actions que permite la ejecución de scripts en diferentes sistemas operativos y la generación de reportes de cobertura de código con Codecov. En el caso de `metasurvey` se realizan pruebas en diferentes versiones de R y en diferentes sistemas operativos como Windows, MacOS y Linux, esto permite que el paquete sea compatible con diferentes versiones de R y sistemas operativos.

Todo esto fue realizado en GitHub Actions donde se define un archivo de configuración que permite definir en que situaciones se deben de ejecutar los test junto a las diferentes plataformas y versiones de R. En este caso al utilizar GitFlow que es una metodología de trabajo con git que permite la colaboración y la integración continua de los cambios en un repositorio de git, se puede tener una rama de desarrollo y una rama de producción, donde en la rama de desarrollo se realizan los cambios y se ejecutan los test y en la rama de producción se realiza la publicación en CRAN. Todo esto permite que el paquete sea robusto y que los cambios sean integrados de manera continua en el repositorio. Para la integración de una nueva versión se realizan pull request que son un pedido de integración de cambios en la rama de desarrollo, esto permite que los cambios sean revisados y auditados antes de ser integrados en la rama principal.

Como se puede observar en el código 3.3, se define un archivo de configuración que permite definir en que situaciones se deben de ejecutar los test junto a las diferentes

plataformas y versiones de R, esto es lanzado automáticamente cuando se hace un cambio en la rama de desarrollo o en la rama de producción puede aquí verse el historial y ejemplos del mismo [paquete](#).

En capítulos posteriores se presentará la implementación de conceptos de workflows, meta-programación y metodologías de estimación de varianzas en **metasurvey** para la generación de indicadores sociales.

Código 3.3 Archivo de configuración de GitHub Actions para la ejecución de tests en diferentes sistemas operativos y versiones de R.

```
on:
  push:
    branches:
      - main
      - develop
  pull_request:
    branches: [develop]

name: R-CMD-check

jobs:
  R-CMD-check:
    runs-on: ${ matrix.config.os }

    name: ${ matrix.config.os } (${ matrix.config.r })

    strategy:
      fail-fast: false
      matrix:
        config:
          - {os: macos-latest,   r: 'release'}
          - {os: windows-latest, r: 'release'}
          - {os: ubuntu-latest,  r: 'devel', http-user-agent: 'release'}
          - {os: ubuntu-latest,  r: 'release'}
          - {os: ubuntu-latest,  r: 'oldrel-1'}

    env:
      GITHUB_PAT: ${ secrets.GITHUB_TOKEN }
      R_KEEP_PKG_SOURCE: yes

    steps:
      - uses: actions/checkout@v4

      - uses: r-lib/actions/setup-pandoc@v2

      - uses: r-lib/actions/setup-r@v2
        with:
          r-version: ${ matrix.config.r }
          http-user-agent: ${ matrix.config.http-user-agent }
          use-public-rspm: true

      - uses: r-lib/actions/setup-r-dependencies@v2
        with:
          extra-packages: any::rcmdcheck
          needs: check

      - uses: r-lib/actions/check-r-package@v2
        with:
          upload-snapshots: true
```

Capítulo 4

Desarrollo y metodología

Note

Este capítulo está en proceso de validación. Cualquier comentario es bienvenido

En este capítulo se divide en dos partes, la primera parte se centra en la metodología de los métodos de estimación de varianzas y errores estándar, donde se describen los diferentes métodos de remuestreo y se explican las ventajas de los pesos replicados. La segunda parte se centra en el desarrollo e implementación de las diferentes partes del paquete así como también . Los ejemplos de código se muestran con código real del paquete `metasurvey` y donde allí se explican las diferentes partes del código y su funcionamiento intentando ser lo más expositivo posible para que el lector pueda entender el funcionamiento de la meta-programación aunque estos no sean los ejemplos más complejos que se encuentran en el paquete.

4.1 Estimación de los errores estándar

Como se presentó en el capítulo 2, la estimación de errores estándar es fundamental para cuantificar la incertidumbre en las estimaciones. En este capítulo nos centraremos en la implementación práctica de estos métodos en el paquete `metasurvey`.

Cada estimador tiene asociado un error estándar que permite cuantificar la variabilidad de la estimación, debido a que la muestra es aleatoria esta medida es una variable aleatoria. Dentro de la incertidumbre puede separarse en errores muestrales y no muestrales. Los primeros refieren a la variabilidad de la estimación debido a la selección de la muestra y los segundos refieren a la variabilidad de la estimación debido a errores de medición, errores de no respuesta, entre otros (Särndal, Swensson, and Wretman 2003).

En este trabajo se centra en la estimación de los errores muestrales, ya que los errores no muestrales son difíciles de cuantificar. Los errores muestrales se pueden cuantificar mediante la varianza de la estimación. Esta varianza depende del diseño muestral ya que, como se mencionó anteriormente, el diseño muestral induce propiedades estadísticas claves como la distribución en el muestreo, valores esperados y varianzas de estimadores poblacionales. El paquete `survey` permite estimar la varianza de la estimación de forma sencilla y eficiente, sin embargo, en algunos casos la estimación de la varianza no es correcta, ya que el paquete `survey` asume un muestreo simple con probabilidades de inclusión desiguales y con reposición, es decir, con una fracción de muestreo $f = \frac{n}{N} \approx 0$ (Lumley 2004).

Para diseños multietápicas, las probabilidades de segundo orden son muy complejas de calcular, por lo que una estimación directa no es muy factible. Además, estos ponderadores no son exactamente los pesos muestrales definidos en los capítulos anteriores, ya que se ajustan para tener en cuenta la no respuesta y la calibración, lo cual permite una estimación más precisa de ciertas variables de interés. En el caso de que se cuente con un mecanismo para obtener las probabilidades de inclusión de segundo orden, este no tendría en cuenta el proceso posterior de calibración, por lo que la estimación de la varianza no sería correcta.

En general, para este tipo de casos se utilizan principalmente las siguientes estrategias: el método del último conglomerado, donde se asume que la variabilidad proviene únicamente de la selección en la primera etapa, y métodos de remuestreo como el Bootstrap o Jackknife. En este trabajo se propone la implementación de forma nativa de diferentes métodos utilizando solamente un argumento al cargar la encuesta, permitiendo a usuarios no expertos en metodología de muestreo obtener estimaciones de varianzas correctas y confiables.

Adicionalmente, para estimadores no lineales se utiliza el método de Linearización de Taylor, que permite aproximar el estimador como función de estimadores lineales. Un caso típico es la tasa de desempleo, que se calcula como el cociente entre la población desocupada y la población económicamente activa. En este caso, se puede aproximar la tasa de desempleo como función de estimadores lineales y obtener una estimación de la varianza de la tasa de desempleo o, de forma similar, un estimador de medias o proporciones.

4.1.1 Métodos de remuestreo

Mientras que en el capítulo 2 se presentó la teoría detrás de los métodos de remuestreo, aquí nos enfocamos en su implementación práctica y las ventajas que ofrece el enfoque de pesos replicados:

La estimación del error estándar de una media u otros resúmenes poblacionales se basa en la desviación estándar de dicho estimador a través de múltiples muestras independientes. Sin embargo, en encuestas reales solo se cuenta con una muestra. El enfoque de **pesos replicados** ofrece una alternativa, al calcular la variabilidad del estimador a partir de múltiples subconjuntos que se comportan de manera parcialmente independiente, y luego extrapolar esta variabilidad para obtener una estimación que se asemeje a la que se obtendría si se tuvieran múltiples muestras independientes.

Réplicas de Mitad de Muestra

Para entender mejor este método, se puede considerar un diseño estratificado en el que se seleccionan dos unidades por estrato. Si se dividen los datos en dos mitades, tomando una unidad de cada estrato, se crean subconjuntos que se pueden considerar como “mitades” independientes. Si la corrección por población finita no es relevante, la varianza de un estimador basado en una mitad de muestra es aproximadamente el doble de la varianza de la muestra completa. Dado que se tienen dos mitades, se puede usar la diferencia entre sus estimaciones para calcular la varianza:

$$\text{Var}(\hat{\theta}) \approx \frac{1}{2}(\hat{\theta}_A - \hat{\theta}_B)^2,$$

donde $\hat{\theta}_A$ y $\hat{\theta}_B$ son las estimaciones de cada mitad de la muestra. Este enfoque es sencillo pero puede ser inestable, por lo que se suelen usar múltiples conjuntos de divisiones para obtener un promedio más preciso.

Balanced Repeated Replication (BRR)

El método de **Balanced Repeated Replication (BRR)** es una forma sistemática de elegir subconjuntos de la muestra, garantizando que cada unidad se incluya de manera equilibrada en las réplicas. Esto se logra mediante un balanceo ortogonal, donde cada observación está presente en aproximadamente la mitad de las réplicas, y cada par de unidades de diferentes estratos aparece en las réplicas de forma equilibrada. Con (K) estratos, se puede generar un conjunto de hasta $(K + 4)$ réplicas que produzca una estimación de la varianza que es prácticamente idéntica a la que se obtendría usando todas las (2^K) combinaciones posibles.

La varianza utilizando BRR se calcula así:

$$\text{Var}_{\text{BRR}}(\hat{\theta}) = \frac{1}{R} \sum_{r=1}^R (\hat{\theta}_r - \hat{\theta})^2,$$

donde R es el número de réplicas seleccionadas y $\hat{\theta}_r$ es el estimador obtenido de cada réplica.

Pesos Replicados en Diseños Multietápicos y Complejos

El enfoque de pesos replicados no solo se aplica a diseños simples, sino que también se adapta a **diseños de muestreo multietápicos y diseños complejos**. En estos casos, la estructura de la muestra se complica, ya que puede involucrar varias etapas de selección (por ejemplo, seleccionar primero conglomerados como municipios, luego hogares dentro de los municipios, y finalmente personas dentro de los hogares). Esto hace que la varianza deba considerar la correlación entre unidades seleccionadas en cada etapa.

Para estos diseños, se utilizan métodos como el **Jackknife** y el **Bootstrap**, que permiten manejar la estructura multietápica. Por ejemplo:

- En un diseño **Jackknife**, se ajustan los pesos eliminando una observación o un conglomerado completo en cada réplica, y recalculando el estimador con los datos restantes. Esto puede ajustarse para considerar la estructura de estratos y conglomerados.

$$\text{Var}_{\text{Jackknife}}(\hat{\theta}) = \frac{n-1}{n} \sum_{i=1}^n (\hat{\theta}_i - \hat{\theta})^2$$

donde (n) es el número de observaciones o conglomerados, $\hat{\theta}_i$ es la estimación obtenida cuando se omite la i -ésima unidad, y $\hat{\theta}$ es la estimación con todos los datos.

- En el **Bootstrap**, se seleccionan subconjuntos con reemplazo de cada conglomerado, y se ajustan los pesos según el número de veces que cada unidad aparece en la réplica. Esto es especialmente útil cuando las unidades de muestreo tienen una estructura jerárquica, como es el caso de los diseños multietápicos.

$$\text{Var}_{\text{Bootstrap}}(\hat{\theta}) = \frac{1}{B} \sum_{b=1}^B (\hat{\theta}_b - \hat{\theta})^2,$$

donde B es el número de réplicas y $\hat{\theta}_b$ es el estimador obtenido en la b -ésima réplica.

Ventajas de los Pesos Replicados

Aunque estos métodos requieren más esfuerzo computacional comparados con métodos tradicionales como el estimador de Horvitz-Thompson, son muy versátiles. Facilitan la estimación de errores estándar para diferentes tipos de estadísticas, no solo para medias o totales, y son especialmente útiles cuando se trabaja con diseños de muestreo complejos. Además, permiten obtener errores estándar precisos para estimaciones de subpoblaciones sin necesidad de ajustes adicionales. Esto los convierte en una herramienta poderosa para el análisis de encuestas complejas, especialmente con el soporte de software estadístico moderno.

El paquete **survey** con **svrep** proporciona una implementación robusta de varios métodos de pesos replicados, incluyendo Balanced Repeated Replication (BRR), Jackknife, y Bootstrap. Sin embargo, el uso adecuado de estos métodos a menudo no es tan conocido por usuarios que no son expertos en muestreo. La correcta especificación del diseño y la interpretación de los resultados pueden ser complejas, especialmente en el caso de diseños de muestreo multietápicos o aquellos que requieren calibración.

Dentro de **metasurvey** se busca simplificar el uso de estos métodos, pudiendo especificar el tipo de réplica deseado con un solo argumento al cargar la encuesta o utilizar réplicas brindadas por la institución que publica los microdatos. Además, se busca incorporar medidas de calidad de las estimaciones como el coeficiente de variación, el error relativo y el error absoluto, para facilitar la interpretación de los resultados y la comparación entre diferentes estimaciones y subpoblaciones.

4.2 Desarrollo e Implementación

El desarrollo de **metasurvey** se fundamenta en tres pilares principales: una gestión eficiente de dependencias, una arquitectura modular basada en clases, y el uso de técnicas avanzadas de meta-programación. A continuación, se detalla cada uno de estos aspectos.

4.2.1 Gestión de Dependencias

El diseño de **metasurvey** prioriza la eficiencia y minimalismo en sus dependencias externas. El núcleo del paquete se apoya en **survey** para el procesamiento de encuestas complejas, **data.table** para la manipulación eficiente de datos mediante referencias, y **R6** para la implementación orientada a objetos. Para mejorar la legibilidad del código se utiliza **glue**, mientras que **jsonlite** y **httr** facilitan la comunicación con la API. Esta selección cuidadosa contrasta con versiones anteriores que incluían dependencias más pesadas como **tidyverse** y **rlang**, priorizando ahora la eficiencia y ligereza del paquete.

4.2.2 Arquitectura y Diseño de Clases

El paquete utiliza una arquitectura orientada a objetos mediante **R6**, implementando las siguientes clases principales:

1. **Clase Survey**
 - Almacena la encuesta, metadatos y diseño muestral
 - Mantiene registro de recetas y pasos aplicados
2. **Clase Step**
 - Define transformaciones individuales
 - Gestiona dependencias y evaluación perezosa
3. **Clase Recipe**
 - Agrupa steps y metadatos del proceso
 - Facilita compartir flujos de trabajo
 - Incluye DOI para citación académica
4. **Clase RotativePanelSurvey y PoolSurvey**
 - Extensiones para casos específicos (paneles rotativos y combinación de encuestas)
 - Implementan estimadores especializados

La arquitectura modular facilita la extensión del paquete y protege los objetos mediante encapsulamiento.

4.2.3 Implementación de Meta-programación

La meta-programación en `metasurvey` cumple tres objetivos principales:

1. **Registro Automático de Transformaciones**
 - Cada operación realizada en una encuesta se registra automáticamente
 - Facilita la replicabilidad y transparencia de los análisis
2. **Evaluación Perezosa**
 - Las transformaciones se aplican solo cuando es necesario
 - Optimiza el rendimiento y uso de memoria
3. **Gestión de Dependencias**
 - Identificación automática de variables dependientes
 - Asegura la correcta aplicación de transformaciones en el orden adecuado

Implementar la evaluación perezosa y dependencias fue un gran desafío, ya que requirió un diseño cuidadoso de los métodos para poder trabajar con las expresiones de R y extraer información de las mismas. La meta-programación se encuentra en casi toda la implementación de los `Step` y de las funciones auxiliares que permiten la creación y aplicación de recetas y pasos. Dentro de esta misma sintaxis se permite extraer las expresiones para luego poder compartir las recetas o poder decidir en que momento se aplican los pasos y recetas a la encuesta.

4.2.4 Ejemplos de la implementación

Carga de una encuesta

El paquete puede dividirse en dos partes principales: la carga y procesamiento de encuestas, y la estimación de errores estándar. Dentro de lo que es la carga y procesamiento de encuestas, se incluyen funciones para cargar encuestas en diferentes formatos, como SPSS, STATA, CSV, y RDS, y para realizar operaciones básicas como la selección de variables, la recodificación de categorías, y la creación de indicadores.

Esta implementación puede verse en [load_survey.R](#) donde aquí se define la función principal `load_survey` esta misma se encarga de cargar la encuesta y realizar las operaciones básicas mencionadas anteriormente. Dentro de ella podemos ver que es simplemente un wrapper de diferentes paquetes para cargar la encuesta ya sea `read.spss`

del paquete `foreign` (R Core Team 2023a) para cargar encuestas provenientes en formato SAV o DTA, `fread` de `data.table` (Barrett et al. 2024) para archivos CSV y por último `loadWorkbook` del paquete `openxlsx` (Schauberger and Walker 2024), todas estas funciones se encargan de cargar la encuesta en base a la extensión del archivo, el usuario puede modificar cambiando el `engine` como por ejemplo a `tidyverse` donde la lectura CSV se realiza con `read_csv` del paquete `readr` (Wickham 2023), o `haven` (Wickham, Miller, and Smith 2023) para cargar encuestas en formato SPSS o STATA.

Al cargar la encuesta el usuario debe de especificar el tipo de encuesta que está cargando y la edición de la misma, estos metadatos serán cruciales para poder obtener recetas y pasos de la API de `metasurvey`. Además, se puede especificar el tipo de réplica que se desea utilizar, por defecto se utiliza el método de BRR, pero el usuario puede especificar el método de réplica que desee, ya sea Jackknife o Bootstrap, en el capítulo 5 se menciona como utilizar replicas brindadas por la institución que publica los microdatos y estimadores de cambios netos compuestos.

Una vez definida la carga de datos dentro de la misma implementación se crea un objeto de la clase `Survey` la cual se encuentra definida en `survey.R`. Esta clase es realizada con el paquete `R6` (Chang 2022) y se encarga de almacenar la encuesta, los metadatos, las recetas y los pasos junto al diseño muestral, el usuario puede obtener información con wrappers de cada método para que sea más sencillo de utilizar, como por ejemplo `cat_steps` donde se obtiene todos los pasos que fueron aplicados a la encuesta, `cat_recipes` donde se obtienen todas las recetas que fueron aplicadas a la encuesta, `cat_design` donde se obtiene el diseño muestral, entre otros.

En el código 4.1 se muestra un ejemplo de cómo se carga una encuesta y se obtiene la información de la misma.

Código 4.1 Lectura de la encuesta ECH 2022, fijación del ponderador y obtención de recetas.

```
library(metasurvey)

# Cargar encuesta

## Encuesta ECH 2022
## Se fija el ponderador de la encuesta
## Se obtienen las recetas de la encuesta

ech_2022 <- load_survey(
  metasurvey::load_survey_example(
    "ech",
    "ech_2022"
  ),
  svy_edition = "2022",
  svy_type = "ech",
  svy_weight = add_weight(annual = "w_ano"),
  recipes = get_recipe(
    "ech",
    "2022"
  )
)
```

Dentro de este mismo ejemplo se puede ver que se fija el ponderador de la encuesta, en este caso se fija el ponderador `w_ano` que es el ponderador anual de la encuesta ECH 2022, este ponderador es crucial para la estimación de errores estándar y para la obtención de recetas y pasos de la encuesta.

Clase Step

La clase `Step` es una clase que se encarga de almacenar los pasos que se aplican a la encuesta, esta clase se encuentra definida en `step.R` y se encarga de almacenar los pasos que se aplican a la encuesta, los pasos se aplican a través de recetas que se obtienen de la API de `metasurvey`, los pasos pueden ser de diferentes tipos, como por ejemplo `step_compute` que se encarga de calcular una variable, `step_recode` que se encarga de recodificar una variable, entre otros.

En el código 4.2 se muestra un ejemplo de cómo se crea un objeto de la clase `Step` con una clase de `R6` (Chang 2022) paquete que permite la programación orientada a objetos en R donde tiene aquí se encuentran los atributos de la clase `Step` como `name`, `edition`, `survey_type`, `type`, `new_var`, `exprs`, `call`, `svy_before`, `default_engine`, `depends_on`, `comments`, `bake` en conjunto con el método `initialize` que se encarga de inicializar la clase `Step` con los atributos mencionados anteriormente. Los objetos `Survey`, `Recipe`, `PanelRotativeSurvey` y `PoolSurvey` son clases que se encuentran definidas en el paquete `metasurvey` donde modelar en una clase los diferentes objetos que se utilizan en el paquete permite una mejor organización y estructura del código y facilita la implementación de la meta-programación.

Es importante mencionar que la clase `Step` es una clase que se utiliza internamente en el paquete y no es necesario que el usuario la utilice directamente, sin embargo, es importante mencionarla ya que es una parte esencial del paquete y es utilizada en la implementación de las recetas y pasos de la encuesta, además de que es un ejemplo claro de cómo se puede utilizar la programación orientada a objetos en R para modelar diferentes objetos y clases.

El principal uso de `R6` y no de `S3` o `S4` es que `R6` permite la creación de objetos con estado en conjunto con su propiedad de encapsulamiento, lo cual es esencial para la implementación de la meta-programación, ya que permite almacenar el estado de los objetos y modificarlos a través de métodos, lo cual es esencial para la implementación de las recetas y pasos de la encuesta. Además se puede manejar las copias de los objetos de forma mas sencilla siendo algo que mejora el rendimiento y la eficiencia del paquete.

Lazy evaluation

La evaluación perezosa es una técnica de programación que consiste en retrasar la evaluación de una expresión hasta que sea necesaria. En el contexto de `metasurvey`, la evaluación perezosa se utiliza para retrasar la aplicación de recetas y pasos a la encuesta hasta que sea necesario, lo cual permite optimizar el rendimiento y la eficiencia del paquete. Esto hace que los `Steps` se ejecuten con una validación mínima en base a las dependencias de las variables, y se ejecuten solo cuando se necesiten o al cocinar la receta.

El paquete tiene por defecto la evaluación perezosa de los pasos y recetas, lo cual hace que sea más eficiente y rápido el procesamiento de las encuestas aunque puede llevar a confusiones al usuario cuando revisa los datos de forma manual ya que si bien se

Código 4.2 Definición de la clase `Step` con sus atributos y método `initialize` para inicializar la clase. Las clases de `R6` son encapsuladas y permiten que los métodos y atributos sean privados o públicos.

```
step <- R6Class(
  "Step",
  public = list(
    name = NULL,
    edition = NULL,
    survey_type = NULL,
    type = NULL,
    new_var = NULL,
    exprs = NULL,
    call = NULL,
    svy_before = NULL,
    default_engine = NULL,
    depends_on = list(),
    comments = NULL,
    bake = NULL,
    initialize = function(...args) {
      self$name <- name
      # Inicialización de los atributos de la clase
      # Se omiten por la extensión del código
      # Definir un constructor permite que siempre
      # se inicialicen los atributos de la clase
      # de forma correcta
    },
    method1 = function(...) {
      # Método 1 (Método generico no se muestra por extensión)
    },
    method2 = function(...) {
      # Método 2 (Método generico no se muestra por extensión)
    }
  )
)
```

aplican los `Step` los mismos no tienen efecto hasta que se cocine la receta, el usuario puede desactivar (código 4.3) la evaluación perezosa de los pasos y recetas si lo desea. La evaluación perezosa se implementa a través de la clase `Step` y de la función `bake` que se encarga de aplicar los pasos y recetas a la encuesta.

Código 4.3 Forma de desactivar la evaluación perezosa de los pasos y recetas. Esto hace que los pasos y recetas se apliquen de forma inmediata.

```
metasurvey::set_lazy_processing(FALSE)
```

Uso de copias y referencias

El paquete `data.table` (Barrett et al. 2024) logra una eficiencia en la manipulación de datos al utilizar referencias en lugar de copias, lo cual permite que las operaciones se realicen de forma más rápida y eficiente. Dentro de `metasurvey` al utilizar como motor `data.table` permite que sea eficiente y rápido aunque puede llevar a confusiones al

usuario donde se modifican las referencias de los objetos algo que no es común en R, sin embargo, se puede utilizar la función `copy` para realizar copias de los objetos y no modificar las referencias de los mismos código 4.4.

Código 4.4 Desactivar el uso de referencias y utilizar copias de los objetos.

```
metasurvey::set_use_copy(TRUE)
```

4.2.5 Meta-programación

La meta-programación fue un aspecto clave en el desarrollo de `metasurvey`, ya que permitió que al realizar una operación en una encuesta, se generara un registro de los pasos y recetas aplicados, lo cual es esencial para la replicabilidad y la transparencia de los análisis. La meta-programación se implementó a través de la clase `Survey` y de las funciones auxiliares que permiten la creación y aplicación de recetas y pasos.

Código 4.5 Ejemplo de función para encontrar dependencias de variables en una expresión de un step. Puede encontrar mas ejemplos en el código fuente en la implementación de los Steps.

```
find_dependencies <- function(call_expr, survey) {
  dependencies <- character()

  if (is.call(call_expr)) {
    for (i in seq_along(call_expr)) {
      result <- find_dependencies(call_expr[[i]], survey)
      if (!is.null(result)) {
        dependencies <- unique(c(dependencies, result))
      }
    }
  } else if (
    is.name(call_expr) && as.character(call_expr) %in% names(survey)
  ) {
    dependencies <- unique(c(dependencies, as.character(call_expr)))
  }

  return(unique(dependencies))
}
```

En el código 4.5 se muestra una función auxiliar que permite encontrar las dependencias de variables en una expresión de un `Step`. Esta función se utiliza para identificar las variables que se utilizan en un paso y que deben ser incluidas en el registro de recetas. La función `find_dependencies` recibe una expresión de un paso y un objeto de la clase `Survey`, y devuelve un vector con las variables que se utilizan en el paso. Esta función se utiliza de forma interna en las implementaciones de `step_compute` y `step_recode` para registrar las dependencias esto es un ejemplo claro de como con código se puede extraer información del mismo y utilizarla para otros fines.

La meta-programación también fue utilizada para que el usuario utilice la misma sintaxis del paquete `survey` para definir los estadísticos a estimar y no deba de incluir el diseño el cual ya se encuentra dentro del objeto `Survey`, donde aquí también se encuentran diferentes diseños en base a la periodicidad de la encuesta, algo que es útil cuando se trabaja con encuestas de panel rotativos como la ECH luego de cambio de

metodología en 2021, en el capítulo 5 se menciona como se puede utilizar diferentes diseños en base a la periodicidad de la encuesta y un ejemplo con la encuesta ECH.

Ejemplos Avanzados de Meta-programación

La meta-programación avanzada en R permite manipular ambientes y expresiones de forma dinámica, lo cual es esencial para la implementación de recetas y pasos en `metasurvey`. A continuación, se presentan casos típicos de meta-programación, la manipulación de ambientes y expresiones, y el uso de `substitute` y `bquote` para evaluar expresiones de forma parcial.

Ambientes y Evaluación

Código 4.6 En este ejemplo se crea un nuevo ambiente `env` y se asignan valores a las variables `x`

```
# Crear un nuevo ambiente
env <- new.env()

# Asignar valores en el nuevo ambiente
assign("x", 10, envir = env)
assign("y", 20, envir = env)

# Evaluar una expresión en el nuevo ambiente
eval(quote(x + y), envir = env)
```

Manipulación de Expresiones

Código 4.7

```
# Crear una expresión
expr <- quote(x + y)

# Modificar la expresión
expr[[1]] <- quote(`*`)
expr[[2]] <- quote(x)
expr[[3]] <- quote(y)

# Evaluar la nueva expresión
eval(expr, envir = env)
```

Uso de `substitute` y `bquote`

Estos ejemplos muestran cómo se pueden manipular ambientes y expresiones en R para realizar meta-programación avanzada. La capacidad de modificar y evaluar expresiones dinámicamente es una herramienta poderosa que se utiliza en `metasurvey` para registrar y aplicar transformaciones y brindar la flexibilidad necesaria para adaptarse a diferentes tipos de encuestas y diseños muestrales.

4.2.6 Sistema de Comunicación y Optimización

El paquete implementa una API REST desarrollada en Node.js que permite compartir y gestionar recetas entre usuarios. La API proporciona endpoints para obtener, crear

Código 4.8 En este ejemplo se muestra cómo se pueden reemplazar variables en una expresión utilizando `substitute` y cómo se puede evaluar parcialmente una expresión utilizando `bquote`.

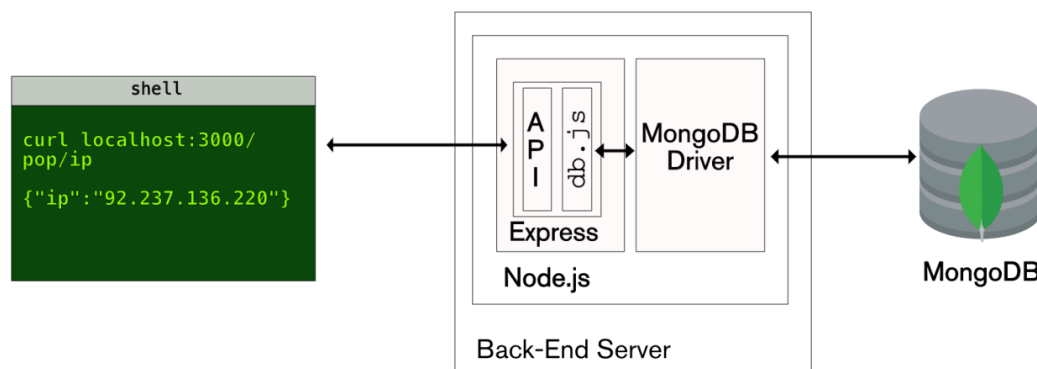
```
# Usar substitute para reemplazar variables en una expresión
expr <- quote(a + b)
substitute(expr, list(a = 1, b = 2))

# Usar bquote para evaluar parcialmente una expresión
bquote(a + .(b))
```

y actualizar recetas, almacenadas en MongoDB. El sistema incluye autenticación mediante tokens JWT, con planes futuros para implementar un portal web de registro automático.

MongoDB se eligió por su flexibilidad y escalabilidad, permitiendo almacenar recetas de forma estructurada y eficiente. Es un sistema de base de datos NoSQL (**Not Only SQL**) enfocada en documentos, en lugar de tablas, se agrupan en colecciones y se almacenan en formato JSON. Esto permite almacenar recetas de forma flexible y escalable, sin necesidad de definir un esquema fijo.

Si bien la dentro de la configuración de la API se define un esquema semi-estructurado para las recetas, se permite la flexibilidad de agregar nuevos campos y estructuras de datos pero se mantiene una estructura mínima para mantener la consistencia de los datos. La API se comunica con el paquete `metasurvey` a través de solicitudes HTTP el usuario no necesita interactuar directamente con la API ya que el paquete se encarga de la comunicación con la misma.



Para optimizar el rendimiento, se implementó un sistema de cache que gestiona proactivamente la memoria mediante liberación de recursos y reutilización de cálculos intermedios. El sistema aprovecha la paralelización automática y el procesamiento por lotes cuando es posible.

La arquitectura modular del sistema facilita la incorporación de nuevos tipos de encuestas y diseños muestrales, permitiendo adaptarse a diferentes necesidades sin modificar el núcleo del paquete.

4.3 Síntesis del capítulo

En este capítulo se ha presentado una revisión detallada de los métodos de estimación de varianzas y errores estándar, así como su implementación en el paquete

metasurvey. Se han descrito las ventajas de utilizar métodos de remuestreo como Bootstrap y Jackknife, y se ha destacado la importancia de los pesos replicados en diseños de muestreo complejos. Además, se ha mostrado cómo **metasurvey** facilita la creación y el manejo de encuestas, permitiendo a los usuarios obtener transformaciones transparentes y reproducibles.

Capítulo 5

Casos de uso

Para este capítulo se presentan dos casos de uso que demuestran la versatilidad y eficacia de `metasurvey` en el análisis de encuestas de hogares en América Latina. Se abordarán dos encuestas representativas de la región: la Encuesta Continua de Hogares (ECH) de Uruguay y la Encuesta Permanente de Hogares (EPH) de Argentina. Estas encuestas son fuentes clave de información sobre el mercado laboral en sus respectivos países y han sido utilizadas en diversos estudios y análisis socioeconómicos.

Note

Este capítulo está en proceso de validación. Cualquier comentario es bienvenido

El paquete `metasurvey` facilita el procesamiento y análisis de encuestas de hogares a través de una interfaz unificada. Este capítulo presenta dos casos de uso que demuestran su versatilidad: el análisis de la Encuesta Continua de Hogares (ECH) de Uruguay y la Encuesta Permanente de Hogares (EPH) de Argentina.

5.1 Encuesta Continua de Hogares con Paneles Rotativos

5.1.1 Contexto y Cambios Metodológicos

En 2021, la ECH adoptó un diseño de panel rotativo, reemplazando su diseño **cross-section** anterior. Este cambio permite el seguimiento de hogares durante seis meses, tras lo cual se incorporan nuevos grupos de rotación en el panel, como se muestra en la Figura 5.1 (Instituto Nacional de Estadística 2021). Esto mejora:

- La precisión de las estimaciones
- El análisis de dinámicas laborales
- La medición de indicadores socioeconómicos
- El estudio de transiciones en el mercado laboral

5.1.2 Carga y Procesamiento de Datos

La ECH ha sido la principal fuente de información sobre el mercado laboral uruguayo desde 1968 y expandió su cobertura nacional en 1980. Los microdatos están disponibles desde 2006 en el portal [ANDA](#) del INE.

Para trabajar con la ECH 2023, se requieren:

- `ECH_implantacion_2023.csv`
- `ECH Seguimiento[1-12].csv`
- Archivos de pesos replicados Bootstrap mensuales (enero-diciembre 2023)

Grupo de rotación (GR)	mes de la encuesta (estimación)										
	2021						2022				
	7	8	8	10	11	12	1	2	3	4	5
1	1ra	2do	3ra	4ta	5ta	6ta	abandona la encuesta				
2		1ra	2do	3ra	4ta	5ta	6ta				
3			1ra	2do	3ra	4ta	5ta	6ta			
4				1ra	2do	3ra	4ta	5ta	6ta		
5					1ra	2do	3ra	4ta	5ta	6ta	
6						1ra	2do	3ra	4ta	5ta	6ta
1							1ra	2do	3ra	4ta	5ta
2								1ra	2do	3ra	4ta
3									1ra	2do	3ra
4										1ra	2do
5											1ra
6											

FIGURA 5.1: Paneles Rotativos, extraído de documento metodológico de la ECH 2023

Un aspecto técnico importante es el manejo eficiente de los pesos muestrales replicados. **metasurvey** optimiza este proceso convirtiendo automáticamente los archivos Excel de pesos bootstrap a formato CSV, mejorando significativamente el rendimiento en análisis posteriores.

5.1.3 Construcción de Variables e Indicadores

El paquete permite dos enfoques para la construcción de variables:

1. Utilizar recetas predefinidas disponibles a través de la API de **metasurvey**
2. Crear recetas personalizadas según necesidades específicas

Por ejemplo, para calcular indicadores del mercado laboral:

A continuación se presentan algunas recetas que se pueden utilizar para calcular las tasas de mercado de trabajo a nivel mensual, trimestral y anual.

En el código 5.3 se crean las variables necesarias para el cálculo de las tasas de mercado de trabajo a partir de los microdatos de seguimiento de la ECH 2023. Las variables creadas son: Población Económicamente Activa (PEA), Población Empleada (PET), Población Ocupada (PO) y Población Desocupada (PD). Una cosa importante es que la variable **POBPCOAC** es una variable construida por el INE que indica la condición de actividad, esta variable se construye a partir de los formularios dentro de **metasurvey** se encuentra a modo de receta la sintaxis publicada hasta la versión 2019 de la ECH, la misma fue basado en archivos PDF donde incluían un script de SPSS para la construcción de la variable. Para años posteriores no fue publicado este documento, se espera en breve dejar disponible la receta para los años 2020 considerando el nuevo formulario y revisando las versiones anteriores.

5.1.4 Estimación de Tasas de Mercado de Trabajo

Una vez creadas las variables básicas, podemos calcular las tasas de actividad, empleo y desempleo utilizando la función **workflow**. Esta función permite realizar estimaciones a diferentes niveles temporales (mensual, trimestral, anual) y con distintos tipos de agregación.

TABLA 5.1: Tasas de mercado de trabajo a nivel trimestral a partir de las estimaciones mensuales de la ECH 2023 con sus respectivos errores estándar y coeficientes de variación.

Indicadores de Mercado de Trabajo
Estimaciones trimestrales a partir de datos mensuales

tasa	Indicador	Periodo	Valor	Error Estándar	CV	Evaluación
Tasa de Desempleo	survey::svyratio: pd/pea	Q1	8.4%	2.7%	0.3160	Excelente
Tasa de Desempleo	survey::svyratio: pd/pea	Q2	8.6%	2.5%	0.2973	Excelente
Tasa de Desempleo	survey::svyratio: pd/pea	Q3	8.1%	2.4%	0.2941	Excelente
Tasa de Desempleo	survey::svyratio: pd/pea	Q4	8.2%	2.4%	0.2894	Excelente
Tasa de Actividad	survey::svyratio: pea/pet	Q1	62.7%	2.0%	0.0320	Excelente
Tasa de Actividad	survey::svyratio: pea/pet	Q2	63.2%	1.7%	0.0275	Excelente
Tasa de Actividad	survey::svyratio: pea/pet	Q3	63.6%	1.7%	0.0273	Excelente
Tasa de Actividad	survey::svyratio: pea/pet	Q4	63.9%	1.8%	0.0275	Excelente
Tasa de Ocupación	survey::svyratio: po/pet	Q1	57.5%	2.0%	0.0348	Excelente
Tasa de Ocupación	survey::svyratio: po/pet	Q2	57.8%	1.8%	0.0307	Excelente
Tasa de Ocupación	survey::svyratio: po/pet	Q3	58.5%	1.7%	0.0289	Excelente
Tasa de Ocupación	survey::svyratio: po/pet	Q4	58.6%	1.6%	0.0281	Excelente

Fuente: Elaboración propia en base a ECH 2023

Estimación por trimestre

```
#> file:///tmp/Rtmp3Euw7W/file23d4176547b0.html screenshot completed
```

Como se puede ver en el código 5.4 se pueden realizar estimaciones a diferentes niveles temporales y con distintos tipos de agregación, en este caso se realizan estimaciones a nivel trimestral a partir de las estimaciones mensuales, el resultado de la estimación se puede ver en la Tabla 5.1.

Estimación de valores anuales

También es posible realizar estimaciones a nivel anual, para esto se debe de considerar las medias de las estimaciones mensuales para cada trimestre y luego realizar la estimación anual.

La nueva metodología puede dar confusiones sobre que microdatos utilizar ya que para estimaciones anuales se consideran los microdatos de implantación y las referidas a mercado de trabajo se consideran los microdatos de seguimiento esto se debe a que el hogar luego de ser seleccionado en la implantación el formulario se realiza por vía telefónica y se centra unicamente a variables referidas al situación de empleo del hogar. Para realizar estimaciones por ejemplo de cantidad de personas que finalizaron un ciclo educativo se debe de considerar los microdatos de implantación a nivel anual.

Si bien dentro de `metasurvey` se pueden realizar estimaciones en diferentes años, es necesario tener cierta consideración del cambio metodológico al momento de interpretar los resultados, situaciones que también ocurrieron en la edición de 2012 y 2006 (“Comunicado Encuesta Continua de Hogares,” n.d.).

```
\newpage
```

```
::: {#tbl-ech-mercado-trabajo-anual}
```

```
::: {.cell}
```

```
::: {.cell-output-display}
```

```

\begin{table}
\caption*{
{\large Indicadores de Mercado de Trabajo} \\
{\small Estimaciones anuales a partir de datos mensuales}
}
\fontsize{9.0pt}{10.8pt}\selectfont
\begin{tabular*}{\linewidth}{@{\extracolsep{\fill}}clrrrrl}
\toprule
tasa & Indicador & Periodo & Valor & Error Estándar & CV & Evaluación \\
\midrule\addlinespace[2.5pt]
Tasa de Desempleo & survey::svyratio: pd/pea & 2023 & 8.3\% & 2.5\% & 0.2992 & Excelente
Tasa de Actividad & survey::svyratio: pea/pet & 2023 & 63.4\% & 1.8\% & 0.0286 & Excelente
Tasa de Ocupación & survey::svyratio: po/pet & 2023 & 58.1\% & 1.8\% & 0.0306 & Excelente
\bottomrule
\end{tabular*}
\begin{minipage}{\linewidth}
Fuente: Elaboración propia en base a ECH 2023\\
\end{minipage}
\end{table}

```

```

:::
:::

```

Tasas de mercado de trabajo a nivel anual a partir de las estimaciones mensuales de 1

```

:::

```

Podemos ver que se obtiene un objeto donde se tiene las estimaciones de las tasas de m

```
## Encuesta Permanente de Hogares de Argentina
```

Para demostrar la versatilidad de `metasurvey`, se presenta un segundo caso de uso co

Podemos hacer algo similar a lo que hicimos con la ECH, en este caso cargamos los mic

```

::: {#1st-eph-2022}

```

```

::: {.cell}

```

```

```.r .cell-code}

```

```

eph2022_3 <- metasurvey::load_survey(
 path = metasurvey::load_survey_example(
 "eph",

```

```

 "eph2022_3"
),
 svy_type = "eph",
 svy_edition = "eph_202302",
 svy_weight = add_weight(
 monthly = "PONDERA"
)
) |>
metasurvey::step_recode(
 "pea",
 ESTADO %in% 1:2 ~ 1,
 .default = 0
) |>
metasurvey::step_recode(
 "pet",
 ESTADO != 4 ~ 1,
 .default = 0
) |>
metasurvey::step_recode(
 "po",
 ESTADO == 1 ~ 1,
 .default = 0
) |>
metasurvey::step_recode(
 "pd",
 ESTADO == 2 ~ 1,
 .default = 0
)

```

```

...

```

Carga de la encuesta permanente de hogares en el tercer trimestre de 2022, se crean las variables necesarias para el cálculo de tasas de mercado de trabajo.

```

...

```

### 5.1.5 Visualización de las recetas

Algo interesante que se puede hacer con `metasurvey` es visualizar las recetas que se utilizan para la construcción de las variables, esto puede ser útil para entender como se construyen las variables y que variables dependen de otras. En este caso se muestra la visualización para la creación de la variable `POBPCOAC` en la ECH 2019, si bien el INE ya incorpora esta variable en los microdatos, se puede ver como se construye la variable en base a otras variables del formulario.

Si bien se puede ingresar a los atributos de la receta para ver las variables que dependen de la misma, se puede visualizar de una forma más amigable con la función `view_graph` como se puede ver en la Figura 5.2.

### 5.1.6 Compartiendo Recetas entre Usuarios

En el ejemplo anterior se descargaron recetas ya definidas pero también se pueden compartir recetas entre usuarios, esto puede ser útil para compartir recetas que se han

```
#> file:///tmp/Rtmp3Euw7W/file23d415973d.html screenshot completed
```




FIGURA 5.2: Flujo de construcción de la variable POBPCOAC en la ECH 2019 y variables de mercado de trabajo que dependen de la misma.

construido en base a la documentación de la encuesta o para compartir recetas que se han construido en base a la experiencia de los usuarios como se ve en el código 5.7.

## 5.2 Resumen

Los casos de uso presentados demuestran la flexibilidad y potencia de **metasurvey** para el procesamiento de diferentes encuestas de hogares:

- En el caso de la ECH, se mostró cómo manejar eficientemente el nuevo diseño de panel rotativo y los pesos muestrales replicados bootstrap para generar estimaciones precisas de indicadores del mercado laboral.
- Con la EPH, se evidenció la capacidad del paquete para adaptarse a diferentes estructuras de datos y metodologías de encuestas, manteniendo una interfaz consistente.
- La visualización de recetas mediante `view_graph()` facilita la comprensión de las dependencias entre variables y la transparencia en la construcción de indicadores.
- La posibilidad de compartir recetas entre usuarios permite aprovechar el conocimiento colectivo y acelerar el proceso de análisis de encuestas.

Estas características hacen de **metasurvey** una herramienta valiosa para investigadores y analistas que trabajan con encuestas de hogares en América Latina, proporcionando un marco unificado y eficiente para el procesamiento y análisis de datos.

---

**Código 5.1** Carga de la encuesta continua de hogares en 2023, se carga la implantación y el seguimiento de la encuesta, se especifica el tipo de encuesta, el peso de la implantación y el peso del seguimiento, en este caso se utilizan pesos replicados bootstrap para el seguimiento de la encuesta.

---

```
path_dir <- here::here("example-data", "ech", "ech_2023")
ech_2023 <- load_panel_survey(
 path_implantation = file.path(
 path_dir,
 "ECH_implantacion_2023.csv"
),
 path_follow_up = file.path(
 path_dir,
 "seguimiento"
),
 svy_type = "ECH_2023",
 svy_weight_implantation = add_weight(
 annual = "W_ANO"
),
 svy_weight_follow_up = add_weight(
 monthly = add_replicate(
 "W",
 replicate_path = file.path(
 path_dir,
 c(
 "Pesos replicados Bootstrap mensuales enero_junio 2023",
 "Pesos replicados Bootstrap mensuales julio_diciembre 2023"
),
 c(
 "Pesos replicados mensuales enero_junio 2023",
 "Pesos replicados mensuales Julio_diciembre 2023"
)
),
 replicate_id = c("ID" = "ID"),
 replicate_pattern = "wr[0-9]+",
 replicate_type = "bootstrap"
)
)
)
```

---

**Código 5.2** Se puede ver las variables que dependen de la receta de ingreso compatibilizado para la ECH 2022.

---

```
ingreso_compatibilizado <- get_recipe(
 svy_type = "ech",
 svy_edition = "2022",
 topic = "ingreso"
)
ingreso_compatibilizado$depends_on
```

---

---

**Código 5.3** Creación de variables para el cálculo de tasas de mercado de trabajo en los microdatos de seguimiento de la ECH 2023.

---

```
ech_2023 <- ech_2023 %>%
 step_recode(
 "pea",
 POBPCOAC %in% 2:5 ~ 1,
 .default = 0,
 comment = "Población Económicamente Activa",
 .level = "follow_up"
) %>%
 step_recode(
 "pet",
 e27 >= 14 ~ 1,
 .default = 0,
 comment = "Población Empleada",
 .level = "follow_up"
) %>%
 step_recode(
 "po",
 POBPCOAC == 2 ~ 1,
 .default = 0,
 comment = "Población Ocupada",
 .level = "follow_up"
) %>%
 step_recode(
 "pd",
 POBPCOAC %in% 3:5 ~ 1,
 .default = 0,
 comment = "Población Desocupada",
 .level = "follow_up"
)

ech_2023_bake <- bake_steps(ech_2023)
```

---

---

**Código 5.4** Estimación de tasas de mercado de trabajo a nivel trimestral a partir de las estimaciones mensuales.

---

```
mercado_trabajo_mensual <-
 workflow(
 survey = extract_surveys(
 ech_2023_bake,
 quarterly = 1:4
),
 survey::svyratio(
 ~ pea,
 denominator = ~ pet
),
 survey::svyratio(
 ~ po,
 denominator = ~ pet
),
 survey::svyratio(
 ~ pd,
 denominator = ~ pea
),
 estimation_type = "quarterly:monthly"
)
```

---

---

**Código 5.5** Estimación de tasas de mercado de trabajo a nivel anual a partir de las estimaciones mensuales.

---

```
mercado_trabajo_anual = workflow(
 survey = extract_surveys(
 ech_2023_bake,
 annual = 2023
),
 survey::svyratio(
 ~ pea,
 denominator = ~ pet
),
 survey::svyratio(
 ~ po,
 denominator = ~ pet
),
 survey::svyratio(
 ~ pd,
 denominator = ~ pea
),
 estimation_type = "annual:monthly"
)
```

---

---

**Código 5.6** Carga de la encuesta y se obtienen las recetas disponibles referidas al tópico de mercado de trabajo.

---

```
ech_2019 <- load_survey(
 path = "https://metasurvey-example-data.s3.us-east-2.amazonaws.com/ech/ech_2019.c",
 svy_type = "ech",
 svy_edition = "2019",
 svy_weight = add_weight(
 annual = "pesoano"
),
 recipes = get_recipe(
 svy_type = "ECH",
 svy_edition = 2019,
 topic = "Mercado de trabajo"
)
)
ech_2019 <- bake_recipes(ech_2019)
```

---

---

**Código 5.7** Compartir receta de clasificación de la población por condición de actividad en la ECH 2019.

---

```
receta <- steps_to_recipe(
 name = "Población por condición de actividad",
 user = "INE-Uruguay",
 svy = ech_2019,
 description = "Clasificación de la población por condición de actividad",
 steps = ech_2019$steps,
 topic = "Mercado de trabajo"
)

publish_recipe(receta)
#> Recipe successfully published to metasurvey API. Thanks for your contribution :).
#> $insertedId
#> [1] "67460152bbbf94383dc9cdd"
```

---



## Capítulo 6

# Pasos a futuro

### Note

Este capítulo está en proceso de validación. Cualquier comentario es bienvenido

El desarrollo de `metasurvey` ha establecido una base sólida para el procesamiento reproducible y transparente de encuestas por muestreo, pero el camino hacia adelante presenta múltiples oportunidades de mejora y expansión. En este capítulo se enumeran las principales direcciones de desarrollo futuro del paquete, abarcando desde optimizaciones técnicas hasta la construcción de una comunidad activa de usuarios y colaboradores, con el objetivo de consolidar a `metasurvey` como una herramienta fundamental en el análisis de encuestas.

### 6.1 Optimización del rendimiento y escalabilidad

Una prioridad inmediata es la implementación de procesamiento paralelo nativo para operaciones con grandes conjuntos de datos. Esta mejora resulta particularmente relevante en dos escenarios principales: cuando se trabaja con encuestas que tienen numerosas réplicas bootstrap, donde el cálculo de errores estándar puede volverse computacionalmente intensivo, y al procesar múltiples años de datos simultáneamente para análisis longitudinales o comparativos.

### 6.2 Expansión de funcionalidades estadísticas

La expansión de capacidades analíticas incluirá la implementación de los métodos de (Deville and Tillé 2005) para estimación de varianzas en diseños complejos, junto con un soporte ampliado para diseños muestrales sofisticados.

### 6.3 Mejoras en la experiencia del usuario

#### Documentación y tutoriales

La documentación se expandirá significativamente con casos de uso reales y tutoriales. Se incluirán viñetas temáticas que cubrirán diferentes tipos de análisis, complementadas por ejemplos dentro del paquete y conjuntos de datos de demostración.

## 6.4 Integración y extensibilidad

### Incorporación de scripts IECON compatibilizado

La integración de los scripts de compatibilización del IECON representa un hito importante en el desarrollo del paquete. Se implementará un sistema completo que incorporará estos scripts como recetas predefinidas, asegurando la consistencia histórica mediante un robusto sistema de versionado. Las validaciones automáticas garantizarán la integridad de las series temporales, mientras que una documentación exhaustiva explicará la metodología subyacente.

Para facilitar el análisis de consistencia entre períodos, se desarrollarán herramientas de visualización especializadas. Estas permitirán a los usuarios identificar rápidamente anomalías y verificar la calidad de las compatibilizaciones realizadas.

### Sistema de validación de recetas

El sistema de validación se estructurará en tres niveles principales:

**Certificación institucional** La validación comenzará con un sistema de certificación que otorgará sellos de verificación a instituciones estadísticas nacionales. Las recetas académicas pasarán por un riguroso proceso de revisión por pares, estableciendo diferentes niveles de confianza según su origen institucional.

**Validación comunitaria** Se implementará un sistema de reputación basado en la experiencia colectiva de los usuarios. La comunidad podrá votar y comentar sobre las recetas compartidas, generando un ranking dinámico de confiabilidad.

**Validación técnica** Un conjunto de métricas automatizadas evaluará aspectos como la consistencia interna, la reproducibilidad y el impacto en las estimaciones. Los administradores institucionales contarán con un panel de control para supervisar y gestionar este proceso.

### API y servicios web

La API se expandirá para facilitar el intercambio de recetas entre usuarios, implementando un sistema robusto de versionado que garantice la compatibilidad a largo plazo. El portal web centralizado permitirá explorar y gestionar recetas públicas, facilitando la colaboración en tiempo real entre equipos de investigación.

## 6.5 Invitar a colaborar

El desarrollo de *metasurvey* pretende continuar luego de la finalización de este trabajo intentando establecer una comunidad activa de usuarios y colaboradores. Se espera que esta comunidad contribuya con nuevas ideas, reporte errores y colabore en la implementación de nuevas funcionalidades. Pueden contribuir a través del repositorio de GitHub.

## 6.6 Control de calidad y certificación

El aseguramiento de la calidad se basará en una estrategia integral que incluirá la ampliación de la cobertura de pruebas automatizadas al 80%, implementación de pruebas end-to-end, y un sistema robusto de validación para recetas compartidas. La

certificación de rOpenSci será un objetivo prioritario, respaldado por chequeos y guías detalladas de mejores prácticas.

## 6.7 Visión a largo plazo

En los próximos años, se espera que **metasurvey** incorpore nuevas metodologías en el análisis de encuestas. En conjunto a una forma de validar y compartir recetas con un sistema de reputación y certificación, se espera que **metasurvey** se convierta en una herramienta fundamental para el análisis de encuestas por muestreo, facilitando la colaboración entre instituciones y contribuyendo al avance metodológico en el análisis de encuestas.

## 6.8 Conclusiones finales y visión de futuro

Las conclusiones de este trabajo se pueden estructurar en tres niveles:

**Logros alcanzados** El desarrollo de **metasurvey** ha demostrado la viabilidad de crear una herramienta que estandariza y hace reproducible el procesamiento de encuestas. Los capítulos anteriores evidencian cómo el diseño modular y el sistema de recetas resuelven problemas fundamentales en el análisis de encuestas.

**Desafíos identificados** A lo largo del desarrollo se identificaron retos importantes, como la necesidad de balancear flexibilidad con estandarización, y la importancia de mantener la eficiencia computacional al procesar grandes volúmenes de datos.

**Perspectivas futuras** El camino de desarrollo planteado en este capítulo busca no solo mejorar las capacidades técnicas del paquete, sino establecerlo como una herramienta fundamental que facilite la colaboración entre instituciones y contribuya al avance metodológico en el análisis de encuestas.

El desarrollo futuro de **metasurvey** se enfocará en convertir el paquete en una herramienta fundamental para el análisis de encuestas, manteniendo su compromiso con la transparencia y reproducibilidad mientras expande sus capacidades. Las mejoras planificadas en rendimiento, funcionalidades, usabilidad e integración, junto con el desarrollo de una comunidad activa, buscan establecer a **metasurvey** como una herramienta de referencia en el análisis de encuestas por muestreo.

Este camino de desarrollo no solo mejorará las capacidades técnicas del paquete, sino que también fortalecerá su rol como herramienta educativa y de investigación, facilitando la colaboración entre instituciones y contribuyendo al avance de la metodología estadística en el análisis de encuestas.

El plan de trabajo se encuentra en un proyecto de GitHub, donde se detallan las tareas y responsables de cada etapa. Se invita a la comunidad a participar activamente en el desarrollo de **metasurvey**, aportando ideas, reportando errores y colaborando en la implementación de nuevas funcionalidades.



# Bibliografía

- Allaire, JJ, Yihui Xie, Jade McPherson, Joseph Luraschi, Kevin Ushey, and Amber Atkins. 2024. *RMarkdown*. <https://rmarkdown.rstudio.com/>.
- Anaconda, Inc. 2024. *Anaconda Distribution*. <https://www.anaconda.com/>.
- “Apache Airflow Documentation.” n.d. <https://airflow.apache.org/docs/latest/>.
- Barrett, Tyson, Matt Dowle, Arun Srinivasan, Jan Gorecki, Michael Chirico, Toby Hocking, and Benjamin Schwendinger. 2024. *Data.table: Extension of ‘Data.frame’*. <https://CRAN.R-project.org/package=data.table>.
- Bechhofer, Sean, Iain Buchan, David De Roure, Paolo Missier, John Ainsworth, Jiten Bhagat, Philip Couch, et al. 2013. “Why Linked Data Is Not Enough for Scientists.” *Future Generation Computer Systems*, Special section: Recent advances in e-science, 29 (2): 599–611. <https://doi.org/10.1016/j.future.2011.08.004>.
- Binder, Martin, Florian Pfisterer, Michel Lang, Lennart Schneider, Lars Kotthoff, and Bernd Bischl. 2021. “Mlr3pipelines - Flexible Machine Learning Pipelines in r.” *Journal of Machine Learning Research* 22 (184): 1–7. <https://jmlr.org/papers/v22/21-0281.html>.
- Breidaks, Juris, Martins Liberts, and Santa Ivanova. 2020. *Vardpoor: Estimation of Indicators on Social Exclusion and Poverty and Its Linearization, Variance Estimation*. Riga, Latvia: Central Statistical Bureau of Latvia. <https://csblatvia.github.io/vardpoor/>.
- Chambers, John M. 2014. “Object-Oriented Programming, Functional Programming and r.” *Statistical Science* 29 (2). <https://doi.org/10.1214/13-STS452>.
- Chang, Winston. 2022. *R6: Encapsulated Classes with Reference Semantics*.
- Chevalier, Martin. 2023. *Gustave: A User-Oriented Statistical Toolkit for Analytical Variance Estimation*. <https://CRAN.R-project.org/package=gustave>.
- Codecov: Code Coverage Insights. 2024. <https://about.codecov.io>.
- “Comunicado Encuesta Continua de Hogares.” n.d. <https://www.gub.uy/instituto-nacional-estadistica/comunicacion/noticias/comunicado-encuesta-continua-hogares>.
- Cook, Di. 2014. “Statistical Computing Research |.” <http://dicook.org/2014/10/05/content/post/2014-10-5-statistical-computing/>.
- Davison, Andrew P, and John E Huth. 2012. “Sumatra: A Toolkit for Reproducible Research.” *arXiv Preprint arXiv:1207.5548*.
- Detomasi, Gabriela Mathieu & Richard. 2020. “Ech: Caja de Herramientas Para Procesar La Encuesta Continua de Hogares.” <https://github.com/calcita/ech>.
- Deville, Jean-Claude, and Yves Tille. 1998. “Unequal Probability Sampling Without Replacement Through a Splitting Method.” *Biometrika* 85 (1): 89–101. <https://www.jstor.org/stable/2337311>.
- Deville, Jean-Claude, and Yves Tillé. 2005. “Variance Approximation Under Balanced Sampling.” *Journal of Statistical Planning and Inference* 128 (2): 569–91. <https://doi.org/10.1016/j.jspi.2003.11.011>.
- Driessen, Vincent. 2010. “A Successful Git Branching Model.” <https://nvie.com/posts/a-successful-git-branching-model/>.

- Ellis, Greg Freedman, and Ben Schneider. 2023. *Srvyr: 'Dplyr'-Like Syntax for Summary Statistics of Survey Data*. <https://CRAN.R-project.org/package=srvyr>.
- Escobar, Emilio L., and Yves G. Berger. 2013. "A New Replicate Variance Estimator for Unequal Probability Sampling Without Replacement." *The Canadian Journal of Statistics / La Revue Canadienne de Statistique* 41 (3): 508–24. <https://www.jstor.org/stable/43186201>.
- Escobar, Emilio Lopez, Ernesto Barrios Zamudio, and Juan Francisco Munoz Rosas. 2023. *samplingVarEst: Sampling Variance Estimation*.
- Expectations, Great. 2024. *Great Expectations Documentation*. Superconductive. <https://docs.greatexpectations.io>.
- GitHub Actions: Automate Your Workflow. 2024. GitHub. <https://github.com/features/actions>.
- Hajek, Jaroslav. 1964. "Asymptotic Theory of Rejective Sampling with Varying Probabilities from a Finite Population." *The Annals of Mathematical Statistics* 35 (4): 1491–1523. <https://doi.org/10.1214/aoms/1177700375>.
- Horvitz, D. G., and D. J. Thompson. 1952. "A Generalization of Sampling Without Replacement from a Finite Universe." *Journal of the American Statistical Association* 47 (260): 663–85. <https://doi.org/10.2307/2280784>.
- Instituto Nacional de Estadística. 2021. "Metodología de La Encuesta Continua de Hogares Instituto Nacional de Estadística." <https://www.inecub.uy>.
- Kluyver, Thomas, Benjamin Ragan-Kelley, Fernando Pérez, Brian Granger, Matthias Bussonnier, Jonathan Frederic, Kyle Kelley, et al. 2024. *Jupyter Notebook*. <https://jupyter.org/>.
- Knuth, Donald E. 1984. "Literate Programming." *The Computer Journal* 27 (2): 97111.
- Kozłowski, Diego, Pablo Tiscornia, Guido Weksler, German Rosati, and Natsumi Shokida. 2020. *Eph: Argentina's Permanent Household Survey Data and Manipulation Utilities*. <https://holatam.github.io/eph/>.
- Kuhn, Max, Hadley Wickham, and Emil Hvitfeldt. 2024. *Recipes: Preprocessing and Feature Engineering Steps for Modeling*. <https://github.com/tidymodels/recipes>.
- Landau, William Michael. 2018. "The Drake r Package: A Pipeline Toolkit for Reproducibility and High-Performance Computing." *Journal of Open Source Software* 3 (21). <https://doi.org/10.21105/joss.00550>.
- . 2021. "The Targets r Package: A Dynamic Make-Like Function-Oriented Pipeline Toolkit for Reproducibility and High-Performance Computing." *Journal of Open Source Software* 6 (57): 2959. <https://doi.org/10.21105/joss.02959>.
- Lumley, Thomas. 2004. "Analysis of Complex Survey Samples." *Journal of Statistical Software* 9 (April): 1–19. <https://doi.org/10.18637/jss.v009.i08>.
- . 2011. *Complex Surveys: A Guide to Analysis Using R*. John Wiley & Sons.
- . 2024. "Survey: Analysis of Complex Survey Samples."
- Mailund, Thomas. 2017. *Advanced Object-Oriented Programming in R: Statistical Programming for Data Science, Analysis and Finance*. SPRINGER.
- Merkel, Dirk. 2014. "Docker: Lightweight Linux Containers for Consistent Development and Deployment." *Linux Journal* 2014 (239): 2.
- Mitchell, Margaret, Simone Wu, Andrew Zaldivar, Parker Barnes, Lucy Vasserman, Ben Hutchinson, Elena Spitzer, Inioluwa Deborah Raji, and Timnit Gebu. 2019. "Model Cards for Model Reporting." In, 220–29. <https://doi.org/10.1145/3287560.3287596>.
- Prabhu, Anirudh, and Peter Fox. 2020. "Reproducible Workflow," December. <http://arxiv.org/abs/2012.13427>.
- Publishing, Quarto. 2024. *Quarto*. <https://www.quartoknows.com/>.

- Python Software Foundation. 2024. *Python 3 Documentation: Venv - Creation of Virtual Environments*. Python Software Foundation. <https://docs.python.org/3/library/venv.html>.
- R Core Team. 2023a. *Foreign: Read Data Stored by 'Minitab', 's', 'SAS', 'SPSS', 'Stata', 'Systat', 'Weka', 'dBase', ...* <https://CRAN.R-project.org/package=foreign>.
- . 2023b. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing. <https://www.R-project.org/>.
- “R Packages (2e).” n.d. <https://r-pkgs.org/>.
- rOpenSci, Brooke Anderson, Scott Chamberlain, Laura DeCicco, Julia Gustavsen, Anna Krystalli, Mauro Lepore, et al. 2024. “rOpenSci Packages: Development, Maintenance, and Peer Review.” Zenodo. <https://doi.org/10.5281/zenodo.10797633>.
- Sandve, Geir Kjetil, Anton Nekrutenko, James Taylor, and Eivind Hovig. 2013. “Ten Simple Rules for Reproducible Computational Research.” *PLOS Computational Biology* 9 (10): e1003285. <https://doi.org/10.1371/journal.pcbi.1003285>.
- Särndal, Carl-Erik, Bengt Swensson, and Jan Wretman. 2003. *Model Assisted Survey Sampling*. Springer Science & Business Media.
- Schauberger, Philipp, and Alexander Walker. 2024. *Openxlsx: Read, Write and Edit Xlsx Files*. <https://CRAN.R-project.org/package=openxlsx>.
- Schneider, Benjamin. 2023. “Svrep: Tools for Creating, Updating, and Analyzing Survey Replicate Weights.” <https://CRAN.R-project.org/package=svrep>.
- Sottile, Anthony, and Contributors. 2024. *Pre-Commit: A Framework for Managing and Maintaining Multi-Language Pre-Commit Hooks*. <https://pre-commit.com>.
- Stodden, Victoria, Friedrich Leisch, and Roger D. Peng. 2014. *Implementing Reproducible Research*. CRC Press.
- Thomas Mailund. 2017. *Metaprogramming in r*. 1st ed. Apress. <https://www.amazon.com/Metaprogramming-Advanced-Statistical-Programming-Analysis/dp/1484228804>.
- Ushey, Kevin, and Hadley Wickham. 2023. *Renv: Project Environments*. <https://CRAN.R-project.org/package=renv>.
- Vargas, Mauricio. 2024. *Casen: Metodos de Estimacion Con Diseno Probabilistico y Estratificado En Encuesta CASEN (Estimation Methods with Probabilistic Stratified Sampling in CASEN Survey)*. <https://pacha.dev/casen/>.
- Vilhøber, Lars. 2020. “Reproducibility and Replicability in Economics.” *Harvard Data Science Review* 2 (4). <https://doi.org/10.1162/99608f92.4f6b9e67>.
- Walker, Kyle, and Matt Herman. 2024. *Tidycensus: Load US Census Boundary and Attribute Data as 'Tidyverse' and 'Sf'-Ready Data Frames*. <https://walker-data.com/tidycensus/>.
- Wickham, Hadley. 2011a. “Testthat: Get Started with Testing.” *The R Journal* 3: 510. [https://journal.r-project.org/archive/2011-1/RJournal\\_2011-1\\_Wickham.pdf](https://journal.r-project.org/archive/2011-1/RJournal_2011-1_Wickham.pdf).
- . 2011b. “Testthat: Get Started with Testing.” *The R Journal* 3: 5–10. [https://journal.r-project.org/archive/2011-1/RJournal\\_2011-1\\_Wickham.pdf](https://journal.r-project.org/archive/2011-1/RJournal_2011-1_Wickham.pdf).
- . 2019. *Advanced r, Second Edition*. CRC Press.
- . 2023. *Httr: Tools for Working with URLs and HTTP*. <https://CRAN.R-project.org/package=httr>.
- Wickham, Hadley, Jennifer Bryan, Malcolm Barrett, and Andy Teucher. 2024. *Usethis: Automate Package and Project Setup*. <https://CRAN.R-project.org/package=usethis>.
- Wickham, Hadley, Peter Danenberg, Gábor Csárdi, and Manuel Eugster. 2024. *Roxygen2: In-Line Documentation for R*. <https://roxygen2.r-lib.org/>.
- Wickham, Hadley, Jay Hesselberth, Maëlle Salmon, Olivier Roy, and Salim Brügge-mann. 2024. *Pkgdown: Make Static HTML Documentation for a Package*. <https://>

- [//CRAN.R-project.org/package=pkgdown](https://CRAN.R-project.org/package=pkgdown).
- Wickham, Hadley, Jim Hester, Winston Chang, and Jennifer Bryan. 2022. *Devtools: Tools to Make Developing r Packages Easier*. <https://CRAN.R-project.org/package=devtools>.
- Wickham, Hadley, Evan Miller, and Danny Smith. 2023. *Haven: Import and Export 'SPSS', 'Stata' and 'SAS' Files*. <https://CRAN.R-project.org/package=haven>.



Apéndice A

Apendice